Multi-Dimensional Apriori-Window: Exact Mining of Dense Itemset Regions over Arbitrary Dimensions

1st Given Name Surname
Dept. Name of Organization
Name of Organization
City, Country
email@example.com

2nd Given Name Surname
Dept. Name of Organization
Name of Organization
City, Country
email@example.com

***Abstract*—大規模小売・疫学・物流データでは、何が密集しているか（アイテムセット）と いつ・どこで密集しているか（時空間領域）を同時に答えることが求められるが、既存手法はこの両方を達成できない：パターンマイニング系手法は領域を出力せず、領域抽出系手法（M-Zoom 等）は直積ブロック制約や反単調性の欠如によりアイテムセット列挙と統合できない。本稿では、アイテムセットとそれが密集する多次元領域を厳密に抽出する 多次元 Apriori-Window を提案する。固定空間開始点ごとに多次元問題を重複時刻を許す 1 次元問題へ還元し、窓内出現数の反単調性を活用した Apriori 枝刈りにより全密集パターンとその任意形状の密集領域を厳密に列挙する。**

提案手法は定義により全密集パターンとその密集領域を厳密に抽出する（F1 = 1.00、Jaccard = 1.00）。多様な形状の密集領域を埋め込んだ合成データでの比較実験では，既存のパターンマイニング系手法はパターン検出 F1 = 0.356–0.917 と密集領域の形状により精度にばらつきが見られた。領域抽出系手法（MZoom・LISA・ST-DBSCAN）は GT パターンを与えても mean Jaccard $\leq$ 0.190 に留まり，スライディング窓定義による密集領域を精度良く近似できなかった。スケーラビリティ実験では，トランザクション数 N を 10^4–10^8 の 4 桁以上にわたって変化させ，N に対する線形スケーリングを確認した（10^8 トランザクションを約 9 分で処理）。さらに犯罪・苦情・地震の d=3–4 実データへの適用により、ドメイン知識と整合する解釈可能な示唆が得られることを確認した。

***Index Terms*—頻出パターンマイニング, 多次元データ, スライディングウィンドウ, 密集領域検出, Apriori, 区間表現**

I. はじめに

A. 動機と応用背景

大規模小売チェーンのデータアナリストは、「どの商品の組み合わせが、どの店舗で、いつ集中的に購買されるか」を知りたいと考える。例えば、100 店舗 × 52 週の POS データから「ビールとポテトチップスは週 46–52（年末商戦）の都市部店舗（店舗 0–9）で集中購買される」という知見は、地域特化の在庫計画やプロモーション施策に直結する。同様に、疫学では特定地域・特定時期に集中する症状の共起パターンが介入ターゲットとなり、物流では地域・時間帯別の出荷量急増パターンがサービス最適化を支援する。

このように多くの分野で多次元データが蓄積されており、そこから時空間局所的な密集パターンを抽出することは、従来の集計分析では得られない知識発見に貢献し得る。

B. 既存手法の限界

上記の応用において分析者が真に必要とする出力は、(i) 何が密集しているか（アイテムセット P）と (ii) いつ・どこで密集しているか（d 次元密集領域）の組 $(P, R(P))$ である。パターン P だけでは「どの店舗にいつ追加発注すべきか」が不明であり、領域 R だけでは「何を発注すべきか」が特定できない。両者が揃って初めて、地域・時期に特化した施策を立案できる。しかし、既存手法はいずれもこの両方を同時に提供できない。

a) パターンマイニング系手法.: 頻出パターンマイニング [1], [2] はグローバルサポートに基づくため局所的密集パターンを見逃す。局所性を考慮した既存手法 [3] も時間軸のみの 1 次元設計にとどまり、多次元の空間情報を活用できない。

b) 領域抽出系手法.: 密部分テンソルマイニング（M-Zoom [4] 等）は直積ブロック制約により任意形状の密集領域にフィットできず、パターン列挙も不正確である（§IIで詳述）。空間統計手法 [5], [6] は時間次元を扱えない。スキャン統計 [7] はアイテムセットの概念を持たない。ST-DBSCAN [8] は点近傍密度に基づくため背景密度と区別された局所的密集を検出できず、反単調性も満たさないため Apriori 枝刈りと統合できない。

C. 本研究の貢献

本稿では、任意の d 次元グリッド（時間 + d–1 個の空間・カテゴリ次元）上で全密集パターンとその密集領域を厳密に抽出する **多次元 Apriori-Window** を提案する（§IV）。提案手法の特長を一言で表すと、**アナリストが「いつ・どこで・何が売れるか」をスライディング窓密集定義のもとで厳密に抽出できる**ことである。

本研究の技術的本質は、1 次元 Apriori-Window [3] の密集区間計算を、固定空間開始点ごとの時間多重集合へ適用する形で d 次元へ拡張した点にある。すなわち、多次元化しても本質的に解いているのは 重複を許す *1* 次元 *Apriori-Window* である。

この多次元化を実現するために、以下の 3 つの技法を導入する。

1) **固定空間開始点ごとの 1D 還元**：各空間開始点 $\boldsymbol{s}_{\mathrm{sp}}$ ごとに、その空間窓に入るパターンの出現を時刻の多重集合 $L_P(\boldsymbol{s}_{\mathrm{sp}})$ へ潰す。これにより d 次元問

題は、空間開始点をキーとする複数の 1 次元問題に分解される。

2) $(k-1)$**-部分集合 interval map の交差による Apriori 枝刈り**：前レベルの密集領域を空間開始点ごとの時間区間列として保持し、候補パターンではそれらを交差して候補区間を作る。これにより $k \geq 2$ でも 1 次元と同型の区間ベース枝刈りが適用できる（Lemma 1）。
3) **duplicate-aware** t **軸ストライド**：2 次元以上では同一時刻の重複が生じる。1 点ずつ密集開始点を保持するのではなく、現在窓だけで密集が保証される左端の連続ブロックをまとめて処理し、密集区間として出力する（Lemma 2）。

II. 関連研究

本研究は、時空間トランザクションデータから密集アイテムセット領域を発見する問題を扱う。この問題は 2 つの研究系譜の交点に位置する：(1) アイテムセットの列挙を目的とするパターンマイニング系譜と、(2) 多次元空間における密集ブロックの検出を目的とする密ブロック検出系譜である。以下では両系譜を整理し、本研究がなぜその交点に位置するかを明確にする。

A. パターンマイニング系譜

a) 頻出アイテムセットマイニング（*FIM*）*.:* Agrawal ら [1] の Apriori アルゴリズムは、アイテムセットの単調性（部分集合は常に親集合以上のサポートを持つ）を利用して候補空間を大幅に枝刈りする。Han ら [2] の FP-Growth は接頭辞木を用いてさらに高速化する。これらは静的なトランザクションデータベース全体のグローバルサポートを基準とするため、局所的に密集したパターンを見逃すという根本的な問題を抱える [3]。

b) 局所密集区間検出手法*.:* 局所密集区間の検出を目的として、連続する出現タイムスタンプ間の間隔に基づく複数の手法が提案されている。LPFIM [9] は連続する 2 出現のギャップが閾値 minthd1 を超えた時点で区間を分割し、局所サポート率が閾値以上かつ区間長が minthd2 以上の区間を出力する。LPPM [10] は余剰累積（spillover）を導入してノイズに頑健な区間検出を実現する。

これらの手法は「連続する 2 出現の時刻差（出現間隔）」を評価することで密集を推定する。しかし、高橋ら [3] が指摘するように、ギャップパラメータがパターン同定精度と区間検出精度の双方を支配するため、両者を同時に高く保つパラメータ設定が一般に存在しないという構造的限界を持つ。さらに、これらの手法は本質的に多次元への拡張が不可能である。d 次元グリッド上の出現点集合には線形順序が存在せず、「連続する 2 出現の間隔」が定義できないためである。

Apriori-Window [3] はこの構造的限界を解消する厳密解法である。出現間隔を介さず、スライディング窓 $[l, l+W]$ 内の出現数を直接計算することで局所頻度を評価するため、ギャップパラメータを必要としない。反単調性に基づく Apriori 枝刈りと t 軸ストライドにより、密集区間を網羅的かつ厳密に列挙する。比較実験では LPFIM・LPPM を大幅に上回る性能を示した [3]。

多次元化が可能な理由：「矩形窓内の出現数」という定義は d 次元でも自然に拡張できる（窓を d 次元直方体 $\prod_k [s_k, s_k + W_k]$ に置き換えるだけ）。出現間隔ベースの手法が線形順序に依存するのと対照的に、Apriori-Window の設計は線形順序を必要としない。本研究はこの観察に基づき、Apriori-Window を 1 次元から任意の d 次元へ拡張する。

c) コロケーションマイニング*.:* コロケーションマイニング [11] は、複数種のフィーチャーが地理的近傍に共存するパターンを参加指数（PI）で評価する。Qian ら [12] はこれを重み付きスライディングウィンドウに拡張した（STCP-Miner）。これらはトランザクション単位の共起ではなく空間的近傍に基づく共起を扱い、密集領域の抽出は対象としない。ただし、パターン識別精度（F1）の観点では比較が可能である（§V-A）。

B. 領域抽出系譜

a) 密ブロック検出系手法*.:* M-Zoom [4] をはじめとする密部分テンソル手法群（テンソル: [13]–[17]、グラフ: SpecGreedy [18]）は、多次元データにおける密ブロックを検出する。各次元で値の集合 $B_k \subseteq D_k$ を選択し、直積ブロック $\prod_k B_k$ の質量/体積比を最大化するグリーディ探索を行う。

これらの手法には 2 つの構造的限界がある。

第一に、出力が直積ブロックに限定される。不規則な形状の密集領域に対しては、過剰な領域を含むか密集セルを取りこぼすかが不可避であり、GT パターンを与えても Jaccard が低下する（§V-Aで実証）。

第二に、パターン列挙が不正確である。アイテムを追加次元として含めれば列挙は試みられるが、直積制約によりブロック内のアイテム集合 C_B の全部分集合が同一領域で密集と仮定され、偽陽性が生じる（§V-Aで実証）。

b) 空間統計手法*.:* LISA [5] は局所 Moran's I で空間ホットスポットを同定し、Getis-Ord G_i^* [6] は局所集中度を z スコアで評価する。いずれも空間次元のみが対象であり、時間スライスごとの個別実行では時間的連続性が失われる。

c) 空間・時空間スキャン統計*.:* Kulldorff [7], [19] の空間/時空間スキャン統計は、円形・円柱形の走査窓で有意なクラスタを検出する。FlexScan [20] は不整形窓への拡張を行った。

上記の統計手法はいずれも変量ごとの異常集中を検出する設計であり、トランザクション内の共起パターン（アイテムセット）を列挙する機能を持たない。全パターンの列挙には $O(2^{|\mathcal{I}|})$ 回の独立実行が必要であり、Apriori 枝刈りとの統合は設計されていない。

d) 時空間密度ベースクラスタリング（*ST-DBSCAN* 等）*.:* ST-DBSCAN [8] は DBSCAN [21] を時空間データに拡張し、空間的距離と時間的距離にそれぞれ独立な閾値 $\varepsilon_1, \varepsilon_2$ を設ける。任意形状のクラスタを出力できるが、第一に、点近傍のカウントにより密度を定義するため、出現が空間的に均一な場合にはデータ全体が単一クラスタとなり、局所的密集を識別できない。第二に、点近傍密度は反単調性を持たないため、全パターンの独立処理 $O(2^{|\mathcal{I}|})$ が不可避である。

TABLE I: 関連手法との比較。「アイテムセット」はパターン列挙能力、「密集領域」は時空間的に局所化された密集領域の出力能力を指す。

手法	アイテムセット	時空間密集領域	領域形状
Apriori [1]	✓	×	—
LPFIM [9] / LPPM [10]	✓	1D のみ	区間
Apriori-Window [3]	✓	1D のみ	区間
コロケーション [11]	✓	×	—
STCP-Miner [12]	✓	×	—
M-Zoom [4] 他	△*	✓	直積のみ
SaTScan [7]	×	✓	円/円柱
FlexScan [20]	×	✓	不整形
LISA [5] / G_i^* [6]	×	空間のみ	任意
ST-DBSCAN [8] 等	×	✓	任意
本手法	✓	✓	任意

* アイテムを次元に含めればパターン出力は可能だが、直積制約により偽陽性が生じ領域分離も不可能。

上記の領域抽出系手法はいずれもアイテムセットの概念を持たないが、GT パターンとその出現密度を与えれば領域抽出器として評価が可能である（§V-A）。

C. 本研究の位置づけ

以上の分析により、既存手法はいずれもパターン列挙と多次元密集領域抽出を同時に達成できないことが示された。本研究は窓内出現数に基づく密集定義の反単調性を利用して Apriori 枝刈りを自然に統合し、両者を単一のフレームワークで実現する。表 Iにこの位置づけを示す。

a) より強い比較手法が存在しない理由.: 表 Iの空白は手法選択の問題ではなく、2 つの列間の構造的非両立性を反映している。パターンマイニング系手法は反単調な密集領域を持たないため時空間ウィンドウを出力できず、領域抽出系手法はアイテムセットの概念を持たないため全 $2^{|\mathcal{I}|}$ 部分集合を独立に処理する必要がありApriori 枝刈りと統合できない。同一カテゴリ内の高速化手法（例：より高速なコロケーションマイナー、より高速な密部分テンソル探索）は同じ構造的制約を共有しており、§V-Aで示す根本的なミスマッチは変わらない。実験の baseline は各手法カテゴリを代表する手法を網羅的に選択しており、本研究が埋めるギャップを包括的に特徴付けている。

III. 問題定義

本節では、Apriori-Window [3] の 1 次元設定を復習し（§III-A）、続いてその d 次元拡張を定式化する（§III-B）。

A. *Apriori-Window*（*1* 次元）

$\mathcal{I} = \{i_1, \ldots, i_m\}$ をアイテム全体集合、$\mathcal{D}_{1\mathrm{D}} = \{(t_n, d_n)\}_{n=1}^{N}$ をタイムスタンプ付きトランザクション列とする。ここで $t_n \in \mathbb{Z}_{\geq 0}$ は整数タイムスタンプ、$d_n \subseteq \mathcal{I}$ はアイテム集合である。

パターン $P \subseteq \mathcal{I}$ の出現列を

$$\mathrm{occ}(P) = \{t_n : P \subseteq d_n\}$$

とする。

定義 1 (区間サポート [3])**.** ウィンドウ幅 W（$W > 0$）のもとで、ウィンドウ左端 l に対するパターン P の区間サポートを

$$\sup(P, l, W) = \left|\{t \in \mathrm{occ}(P) : l \leq t \leq l + W\}\right|$$

と定義する。窓 $[l, l+W]$ は $W+1$ 個の離散時刻を含む。

定義 2 (密集開始点集合と密集区間)**.** サポート閾値 θ に対し、

$$\mathcal{T}_\theta(P) = \{l \in \mathbb{Z}_{\geq 0} : \sup(P, l, W) \geq \theta\}$$

を P の密集開始点集合とする。

$[a, b] \subseteq \mathcal{T}_\theta(P)$ を最大連続成分とする。このとき $[a, b+W]$ を P の密集区間と呼ぶ。

B. d 次元への拡張

$\mathcal{D} = \{(\boldsymbol{b}_n, d_n)\}_{n=1}^{N}$ を d 次元トランザクション列とする。ここで

$$\boldsymbol{b}_n = (b_n^{(0)}, b_n^{(1)}, \ldots, b_n^{(d-1)}) \in \prod_{k=0}^{d-1} \{0, 1, \ldots, N_k - 1\}$$

は整数座標ベクトル（第 0 軸は時間）、$d_n \subseteq \mathcal{I}$ はアイテム集合である。N はトランザクション数を表す。

定義 3 (固定空間開始点への時間多重集合還元)**.** 空間開始ベクトル

$$\boldsymbol{s}_{\mathrm{sp}} = (s_1, \ldots, s_{d-1})$$

と空間ウィンドウ幅 $\boldsymbol{W}_{\mathrm{sp}} = (W_1, \ldots, W_{d-1})$（各 $W_k > 0$）を固定する。軸 k の空間窓 $[s_k, s_k + W_k]$ は $W_k + 1$ 個の離散座標を含む。パターン P の時間多重集合を

$$L_P(\boldsymbol{s}_{\mathrm{sp}}) = \{\{b_n^{(0)} \mid P \subseteq d_n,\ s_k \leq b_n^{(k)} \leq s_k + W_k\ (\forall k = 1, \ldots, d-1)\}\}$$

と定義する。ここで $\{\{\cdot\}\}$ は重複を許す多重集合を表す。

この定義の本質は、固定空間開始点ごとに d 次元問題を重複タイムスタンプを許す *1* 次元問題へ還元することにある。

定義 4 (d 次元スライディングウィンドウサポート)**.** 時間開始点 s_0 と空間開始ベクトル $\boldsymbol{s}_{\mathrm{sp}}$ に対し、パターン P のサポートを

$$S_P(s_0, \boldsymbol{s}_{\mathrm{sp}}) = \left|\{t \in L_P(\boldsymbol{s}_{\mathrm{sp}}) : s_0 \leq t \leq s_0 + W_0\}\right| \quad (1)$$

と定義する。

定義 5 (密集開始点集合と密集領域)**.** 固定空間開始ベクトル $\boldsymbol{s}_{\mathrm{sp}}$ に対し、

$$\mathcal{T}_\theta(P, \boldsymbol{s}_{\mathrm{sp}}) = \{s_0 \in \mathbb{Z}_{\geq 0} : S_P(s_0, \boldsymbol{s}_{\mathrm{sp}}) \geq \theta\}$$

を空間開始点 $\boldsymbol{s}_{\mathrm{sp}}$ における P の密集開始点集合とする。

$[a_j, b_j]$ を $\mathcal{T}_\theta(P, \boldsymbol{s}_{\mathrm{sp}})$ の最大連続成分とする。このとき $[a_j, b_j + W_0]$ を空間開始点 $\boldsymbol{s}_{\mathrm{sp}}$ における P の密集区間と呼ぶ（定義 *2* の自然な拡張）。

全空間開始点にわたる密集区間の集合

$$\mathcal{R}_\theta(P) = \{(\boldsymbol{s}_{\mathrm{sp}}, [a_j, b_j + W_0])\}$$

を P の密集領域と呼ぶ。

a) Apriori 単調性.:

補題 1 (密集開始点集合の単調性)**.** 任意のパターン P とその部分集合 $Q \subset P$、任意の空間開始ベクトル $\boldsymbol{s}_{\mathrm{sp}}$ に対して、

$$\mathcal{T}_\theta(P, \boldsymbol{s}_{\mathrm{sp}}) \subseteq \mathcal{T}_\theta(Q, \boldsymbol{s}_{\mathrm{sp}})$$

が成立する。

証明は付録 Aに示す。

補題 1 より、サイズ k のパターン P の密集開始点集合は P の各 $(k-1)$-部分集合の密集区間に包含される。提案手法ではこの性質を用いて、$(k-1)$-部分集合 *interval map* の交差を候補区間として利用する（§IV-C）。

C. d 次元密集領域検出問題

d 次元密集領域検出問題とは、d 次元トランザクション列 $\mathcal{D}$、ウィンドウ幅 $\boldsymbol{W} = (W_0, W_1, \ldots, W_{d-1}) \in \mathbb{Z}^d_{>0}$、サポート閾値 θ が与えられたとき、各パターン P に対する密集領域の完全な集合 $\mathcal{R}_\theta(P) = \{(\boldsymbol{s}_{\mathrm{sp}}, [a_j, b_j + W_0])\}$ を求める問題である。各軸 k の窓は閉区間 $[s_k, s_k + W_k]$（$W_k + 1$ ビン）である。

IV. 提案手法：多次元 Apriori-Window アルゴリズム

§III-C の問題を解くための **多次元 Apriori-Window アルゴリズム**を提案する。

A. 固定空間開始点による *1* 次元多重集合還元

パターン P と固定空間開始点 $\boldsymbol{s}_{\mathrm{sp}}$ に対し、定義 3 の時間多重集合 $L_P(\boldsymbol{s}_{\mathrm{sp}})$ を構築する。これは P の各出現トランザクションを、そのトランザクションを含みうるすべての空間開始点へ配布することで得られる。

a) 空間開始点への配布.: パターン P を含むトランザクションが離散座標

$$\boldsymbol{b} = (b^{(0)}, b^{(1)}, \ldots, b^{(d-1)})$$

にあるとき、そのトランザクションを含む空間開始点の第 k 成分（$k \geq 1$）は

$$s_k \in [\max(0,\, b^{(k)} - W_k),\; b^{(k)}]$$

を満たす。したがって 1 つの出現は高々

$$W_{\mathrm{sp}} = \prod_{k=1}^{d-1} (W_k + 1)$$

個の空間開始点へ寄与する。

b) 構築コスト.: パターン P の出現トランザクション数を N_P とする。構築には $O(N_P \cdot W_{\mathrm{sp}})$ を要し、ソートを含めた総計算量は $O(\widetilde{N}_P \log \widetilde{N}_P)$ である。ただし $\widetilde{N}_P = N_P \cdot W_{\mathrm{sp}}$ とする。

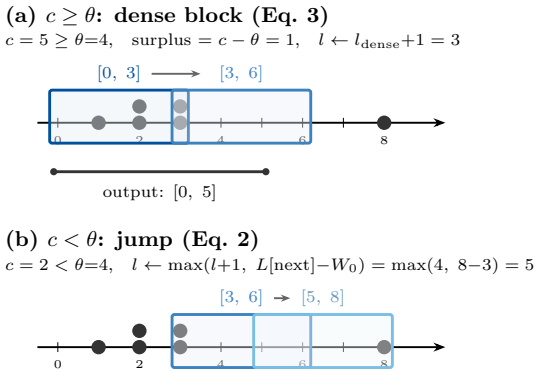


Fig. 1: 重複考慮 t 軸ストライド。ソート済み多重集合 $L = \{\{1, 2, 2, 3, 3, 8\}\}$, W_0=3, θ=4。(a) $c \geq \theta$ のとき，余剰が左端を一括でストライドできる幅を決める（式 (3)）。(b) $c < \theta$ のとき，新たなイベントが入る位置へ窓がジャンプする（式 (2)）。窓の色グラデーション（濃青 → 淡青）は左端 l の進行を示す。

B. t 軸上の重複考慮区間ソルバー

固定空間開始点 $\boldsymbol{s}_{\mathrm{sp}}$ に対し、ソート済み多重集合 $L = L_P(\boldsymbol{s}_{\mathrm{sp}})$ から密集区間を計算する。2 次元以上では複数のトランザクションが同一時刻に存在しうるため、L には重複タイムスタンプが含まれる。このため、1 次元 Apriori-Window の単純な “+1 ジャンプ” をそのまま適用できない。

本手法の工夫は、窓内カウント c と閾値 θ の大小に応じた 2 分岐のストライドにある（図 1）。$c < \theta$（非密集）のとき、窓右端の外側にある次のイベントが入る位置まで l をジャンプし、無駄な走査を省く（式 (2)、図 1(b)）。$c \geq \theta$（密集）のとき、余剰 $c - \theta$ から密集が保証される左端の連続ブロック $[l, l_{\mathrm{dense}}]$ を求め、ブロック全体を一括で密集区間として出力する（式 (3)、図 1(a)）。この一括処理の正確性は補題 2 で保証される。

具体的には、非密集時の左端更新は

$$l \leftarrow \max(l + 1,\; L[\mathrm{next}] - W_0) \tag{2}$$

であり（$L[\mathrm{next}]$ は現在窓の右境界外にある最初のイベント）、密集時の一括ブロック右端は

$$l_{\mathrm{dense}} = L[l_{\mathrm{lo}} + (c - \theta)] \tag{3}$$

で与えられる（l_{lo} は L 中で $\geq l$ となる最初の位置）。密集区間の右端を $l_{\mathrm{dense}} + W_0$ まで延長し、$l \leftarrow l_{\mathrm{dense}} + 1$ と更新する。

補題 2 (密集ブロックの正確性)**.** 式 (3) で定めた l_{dense} に対し、任意の $l' \in [l, l_{\mathrm{dense}}]$ について

$$|\{t \in L : l' \leq t \leq l' + W_0\}| \geq \theta$$

が成り立つ。

証明は付録 Aに示す。

Algorithm 1 固定空間開始点に対する重複考慮密集区間計算

Require: ソート済み多重集合 L、時間窓幅 W_0、閾値 θ
Ensure: 密集区間列 $\mathcal{R}$

$\mathcal{R} \leftarrow \emptyset$
$l \leftarrow \max(0,\, L[\theta-1] - W_0)$
$open \leftarrow$ false
while $l \le L[\text{last}]$ **do**
  $l_{\text{lo}} \leftarrow \text{lower_bound}(L, l)$
  $l_{\text{hi}} \leftarrow \text{upper_bound}(L, l + W_0)$
  $c \leftarrow l_{\text{hi}} - l_{\text{lo}}$
  if $c < \theta$ **then**
    if *open* **then**
      現在の区間を $\mathcal{R}$ に追加
      $open \leftarrow$ false
    end if
    if $l_{\text{hi}} = |L|$ **then break**
    end if
    $l \leftarrow \max(l+1,\, L[l_{\text{hi}}] - W_0)$ ▷ 式 (2)
  else
    $l_{\text{dense}} \leftarrow L[l_{\text{lo}} + (c - \theta)]$ ▷ 式 (3)
    $r_{\text{block}} \leftarrow l_{\text{dense}} + W_0$
    現在の区間を (l, r_{block}) で開始または延長
    $open \leftarrow$ true
    $l \leftarrow l_{\text{dense}} + 1$
  end if
end while
if *open* **then**
  現在の区間を $\mathcal{R}$ に追加
end if
return $\mathcal{R}$

C. *Apriori* 枝刈りによる候補区間制限（$k \ge 2$）

補題 1 を再帰的に適用すると、サイズ k のパターン P の任意の密集開始成分は P の各 $(k-1)$-部分集合の密集区間にも含まれる。この性質を用いて、候補パターン P には $(k-1)$-部分集合 *interval map* の交差を使用する。

a) 候補 interval map.: パターン Q の密集領域を

$$\mathcal{R}_\theta(Q) = \{(\boldsymbol{s}_{\text{sp}}, [a, e])\}$$

とする。同じ空間開始点 $\boldsymbol{s}_{\text{sp}}$ に属する時間区間列を $\mathcal{R}_\theta(Q)[\boldsymbol{s}_{\text{sp}}]$ と書く。サイズ k の候補パターン P の候補 interval map を

$$\mathcal{C}(P, \boldsymbol{s}_{\text{sp}}) = \bigcap_{Q \in \binom{P}{k-1}} \mathcal{R}_\theta(Q)[\boldsymbol{s}_{\text{sp}}] \tag{4}$$

と定義する。

ここでの交差は時間区間に対する標準的な区間交差である。$\binom{P}{k-1}$ は P の全 $(k-1)$-部分集合を表す。すべての空間開始点で $\mathcal{C}(P, \boldsymbol{s}_{\text{sp}}) = \emptyset$ ならば、P は密集区間を持ちえないため枝刈りされる。$k = 2$ では $\binom{P}{1}$ は singleton 集合に一致するため、各 item の密集区間を交差する特殊ケースとなる。

Algorithm 2 多次元 Apriori-Window（区間ベース実装）

Require: d 次元トランザクション列 $\mathcal{D}$、$(\boldsymbol{W}, \theta)$
Ensure: 各パターン P の密集領域 $\mathcal{R}_\theta(P)$

for all $i \in \mathcal{I}$ **do**
  $L_i(\boldsymbol{s}_{\text{sp}}) \leftarrow$ 空間開始点ごとの時間多重集合を構築
  $\mathcal{R}_\theta(\{i\}) \leftarrow$ 各 $\boldsymbol{s}_{\text{sp}}$ で Algorithm 1 を実行
end for
$\mathcal{F}_1 \leftarrow \{\{i\} : \mathcal{R}_\theta(\{i\}) \neq \emptyset\}$
$k \leftarrow 2$
while $\mathcal{F}_{k-1} \neq \emptyset$ **do**
  cands $\leftarrow$ GenerateCandidates($\mathcal{F}_{k-1}$)
  cands $\leftarrow$ PruneCandidates(cands, $\mathcal{F}_{k-1}$)
  $\mathcal{F}_k \leftarrow \emptyset$
  for all $P \in$ cands **do**
    $\mathcal{C}(P, \boldsymbol{s}_{\text{sp}}) \leftarrow \bigcap_{Q \in \binom{P}{k-1}} \mathcal{R}_\theta(Q)[\boldsymbol{s}_{\text{sp}}]$ ▷ 式 (4)
    if すべての $\boldsymbol{s}_{\text{sp}}$ で $\mathcal{C}(P, \boldsymbol{s}_{\text{sp}}) = \emptyset$ **then**
      continue
    end if
    $L_P(\boldsymbol{s}_{\text{sp}}) \leftarrow$ パターン P の時間多重集合を構築
    $\mathcal{R}_\theta(P) \leftarrow$ 各 $\boldsymbol{s}_{\text{sp}}$ で候補区間版重複考慮ソルバーを実行
    if $\mathcal{R}_\theta(P) \neq \emptyset$ **then**
      $\mathcal{F}_k \leftarrow \mathcal{F}_k \cup \{P\}$
    end if
  end for
  $k \leftarrow k + 1$
end while
return $\{\mathcal{R}_\theta(P)\}$

TABLE II: 提案手法の計算量。N_P: パターン P を含むトランザクション数、$W_{\text{sp}} = \prod_{k=1}^{d-1}(W_k + 1)$、$\widetilde{N}_P = N_P W_{\text{sp}}$、$I_P$: 候補 interval map の総区間数。

ステップ	計算量
L_P の構築	$O(N_P \cdot W_{\text{sp}})$
L_P のソート	$O(\widetilde{N}_P \log \widetilde{N}_P)$
時間区間計算	$O\Big(\sum_{\boldsymbol{s}_{\text{sp}}} \lvert L_P(\boldsymbol{s}_{\text{sp}})\rvert \log \lvert L_P(\boldsymbol{s}_{\text{sp}})\rvert\Big)$
候補 interval map 交差	$O(I_P)$

b) 厳密再評価.: $\mathcal{C}(P, \boldsymbol{s}_{\text{sp}}) \neq \emptyset$ の場合にのみ、トランザクション列を 1 回走査して $L_P(\boldsymbol{s}_{\text{sp}})$ を構築し、Algorithm 1 の候補区間版を $\mathcal{C}(P, \boldsymbol{s}_{\text{sp}})$ に対して実行する。

D. アルゴリズム全体と計算量

したがって、現行実装に忠実な全体計算量は

$$O\left(\sum_{P \in \mathcal{F}} \left(N_P W_{\text{sp}} + \widetilde{N}_P \log \widetilde{N}_P + I_P\right)\right)$$

である。ここで $\mathcal{F}$ は実際に評価された候補パターンの集合である。実用的な計算量を支配する主要因は $|\mathcal{F}|$ であり、Apriori プルーニング（補題 1）によって制御される：

$(k-1)$-部分集合の候補区間マップが空であるパターンは評価なしに枝刈りされ、$|\mathcal{F}|$ は密集パターンの集合に収まる。最悪ケースでは、全アイテムセットが密集している場合に $|\mathcal{F}|$ は $|\mathcal{I}|$ に対して指数的に増大するが、これは厳密列挙アルゴリズムに固有の制約であり、実際のトランザクションデータの疎性によって緩和される。実データへの適用時には、連続座標の離散化が前処理として必要となる（§V）。

V. 実験

提案手法の有効性とスケーラビリティを検証する。全実験は Rust（リリースビルド）で実装し、Apple M3（8 コア、24 GB RAM）上で実行した。

A. *EX-1*：多様な形状の密集領域における手法比較（合成データ）

a) 目的.: 実データの密集領域はさまざまな形状をとりうる。本実験では矩形・ドリフト・断続・拡大の 4 種類の埋め込み形状を含む合成データを用いて、既存手法が提案手法の定義する厳密解をどの程度復元できるかを検証する。

b) 合成データ.: 時間軸の格子点数 T=100、空間軸の格子点数 S=100 のグリッド上に 20 個の GT パターンを埋め込んだ合成データを使用する。矩形（Shape A）・ドリフト（Shape B）・断続（Shape C）・拡大（Shape D）の 4 形状を設定し、各形状につき 3 シード（計 12 データセット）で評価した。生成の詳細は Appendix Bを参照。

c) 比較手法.: 各比較手法は提案手法とは異なる定式化に基づくため、公平な比較のためパラメータをグリッドサーチにより最良スコアが得られるよう調整した。以下の 5 手法を用いる。Colocation / STCP-Miner は EX-1-1（パターン検出）で用い、LISA / MZoom / ST-DBSCAN は EX-1-2（密集領域復元）で用いる。

- **Colocation** [11]: 空間コロケーションマイニング。PI 閾値 τ をグリッドサーチ。
- **STCP-Miner** [12]: Colocation の時空間ウィンドウ拡張。τ およびウィンドウ幅をグリッドサーチ。
- **MZoom** [4]: GT パターン P の出現テンソルに対する貪欲密集ブロック検出。Top k をグリッドサーチ。
- **LISA** [5]: GT パターン P の出現回数を空間グリッドに集約し、Local Moran's I で High-High セルを特定。
- **ST-DBSCAN** [8]: GT パターン P の出現セルに対し ε_1、ε_2、min_pts をグリッドサーチ。

d) 評価指標.: 合成データに陽に埋め込んだパターンに対し、スライディング窓定義（定義 3–5）のもとで得られる密集パターン集合 P^* および密集領域 $R^*(P)$ を正解（GT）とする。提案手法はこの定義の厳密解を出力するため、定義により F1 = 1.00、Jaccard = 1.00 となる。これは性能の主張ではなく厳密性の検証であり、本手法が解くべき問題を正しく解けていることを確認するものである。EX-1-1 では各手法が GT パターン集合 P^* をどの程度特定できるかを F1 $= 2|\hat{P} \cap P^*|/(|\hat{P}| + |P^*|)$ で測る。EX-1-2 では各 $P \in P^*$ に対する GT 密集領域 $R^*(P)$ をどの程度復元できるかを平均 Jaccard $= \frac{1}{|P^*|}\sum_{P\in P^*} |R^*(P) \cap \hat{R}(P)|/|R^*(P) \cup \hat{R}(P)|$ で測る。

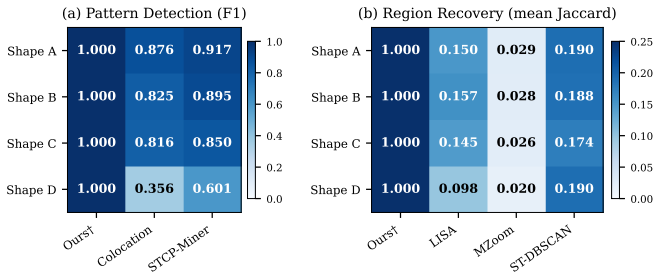


Fig. 2: EX-1 の結果（3 シード平均、p_{embed}=0.25）。(a) EX-1-1 F1；(b) EX-1-2 平均 Jaccard。GT はスライディング窓定義（定義 3–5）に基づく厳密解。† 提案手法は定義により厳密解を出力するため F1 = 1.00、Jaccard = 1.00。各比較手法はグリッドサーチで最大スコアのパラメータを採用。

なお、各比較手法は本質的に異なる定式化を解いている：コロケーション系手法は参加指数に基づく共起を検出し密集領域を出力しない；密部分テンソル系手法はスライディング窓ではなく直積ブロックを出力する；クラスタリング系手法は点近傍密度を扱い窓内出現数とは異なる。EX-1 は競争実験ではなく、各手法がスライディング窓の厳密解をどの程度近似できるかを特徴付けることを目的とする。この密度定義が実用上意味のあるパターンを捉えていることの独立した根拠は、EX-3（§V-C）において示される：抽出された密集領域は、ground-truth の監督なしにドメイン知識と整合する解釈可能な現象に対応する。

e) 提案手法のパラメータ.: 全形状共通：$W = (20, 5)$、$\theta = 30$。

f) 分析.: Fig. 2に各形状・各手法のスコア（3 シード平均）を示す。*EX-1-1*（パターン検出 *F1*）。Colocation は特に Shape D（拡大）で最低となる。密集の拡大過程でグローバル PI 計算が全期間にわたって希釈されるためである。STCP-Miner は時間ウィンドウで希釈を部分的に回避し改善するが、近似誤差は残る。

EX-1-2（密集領域復元・平均 *Jaccard*）。既存手法は全形状で低スコアにとどまる。

LISA は全時刻の出現を集約して時間情報を失うため，密集範囲を復元できない。

MZoom が最も低スコアとなる。S=100 のグリッドに対して密集帯が 5 セル幅であるため、直積ブロック制約のもとでは帯全体を覆う矩形ブロックを取ると密度が著しく低下する。その結果、貪欲探索は単一列（幅 1）のブロックに収束し、帯の大部分を偽陰性として見落とす。

ST-DBSCAN は出現セルのみをクラスタメンバとしてラベルするため、密集ウィンドウ内の非出現セル（密集領域の構成要素の大部分）を系統的に見落とす。

以上の低スコアはパラメータ調整の問題ではなく、各手法がスライディング窓定義とは本質的に異なる出力を生成するという構造的なミスマッチに起因する。同一カ

テゴリ内の高速化手法も同じ制約を共有するため、追加しても結果は等価となる（§II）。

B. EX-2：スケーラビリティ（合成データ）

a) 目的.: 時間格子点数 T、空間格子点数 S、次元数 d、アイテム数 $|\mathcal{I}|$ の 4 パラメータそれぞれについて、計算時間とピークメモリがどのようにスケールするかを独立に検証する。

b) 合成データ生成.: d 次元格子上で、各アイテムを全セルに対して独立に Bernoulli(p_{item}=0.10) からサンプリングし 1 バスケットを構成する。空セルにはアイテム 1 を割り当て、各セルに正確に 1 トランザクションが存在することを保証する（生成の詳細は Appendix C）。

c) 提案手法のパラメータ.: $W = (24, 4)$、$\theta = 15$ を全実験で固定。基準設定：T=1,000、S=100、d=2、$|\mathcal{I}|$=20。

d) 実験設計.: 4 軸を独立に変化させる：(a) $T \in \{10^2, 10^3, 10^4, 10^5\}$（$S$=100、$d$=2 固定）；(b) $S \in \{10, 10^2, 10^3, 10^4\}$（$T$=1,000、$d$=2 固定）；(c) $d \in \{2, 3, 4\}$（空間次元を調整して $N \approx 10^5$ を固定）；(d) $|\mathcal{I}| \in \{20, 40, 60, 80\}$（$T$=1,000、$S$=100、$d$=2 固定）。

e) 分析.: Fig. 3に 4 軸の計算時間とピーク RSS を示す。

(a)(b) T・S スケーラビリティ. 実行時間・ピークメモリともに N に対しておおむね線形にスケールする。N が 10^4 から 10^7 へ 10^3 倍増加すると、実行時間は 0.046 s から 49.5 s へ（$\approx 10^3$ 倍）、ピークメモリは 4.9 MB から 2,135 MB へと増加する。N=10^8（T=10^6、S=100）の拡張実行では 517 s（< 9 分）で完了し、線形スケーリングと整合する。同一 N での T/S 比率の影響として、N=10^7 において T=$10^5/S$=10^2 が 49.5 s であるのに対し T=$10^3/S$=10^4 は 59.8 s（1.21 倍）であり、T が大きいほど t 軸ストライド（Lemma 2）によるギャップスキップが有効に働く。

(c) d スケーラビリティ. $N \approx 10^5$ を固定した状態で d を 2 から 4 へ増やすと、W_{sp} は 5 から 125（25 倍）に増加するが、ピークメモリは 26 MB から 35 MB（1.35 倍）の増加にとどまる。これは各空間始点のマルチセットが疎であるため、W_{sp} の増加がメモリに直結しないことを示す。

(d) $|\mathcal{I}|$ スケーラビリティ. $|\mathcal{I}|$ が 20 から 80 へ増加すると実行時間は 0.44 s から 6.8 s へ増加する。指数的増加よりも大幅に緩やかであり、Apriori プルーニングが非密集パターンの候補生成を抑制しているためである。

C. EX-3：実データへの適用（d=3–4）

a) 目的.: 提案手法を多様なドメインの実データに適用し、検出されたパターンと密集領域がドメイン知識と整合する解釈可能な示唆を与えることを確認する。

b) データセットと結果.: 犯罪報告 2 種（Chicago Crime [22]、NYPD Crime [23]）、市民苦情（NYC 311 [24]）、地震カタログ（USGS Earthquake [25]）の 3 ドメイン・d=3–4 の実データセットを使用した。時間を週単位、空間座標を等幅ビンに離散化し、各セルの発生事象をアイテムとするトランザクションデータに変換した。データセットの詳細および定量的結果は付録 Dに示す。

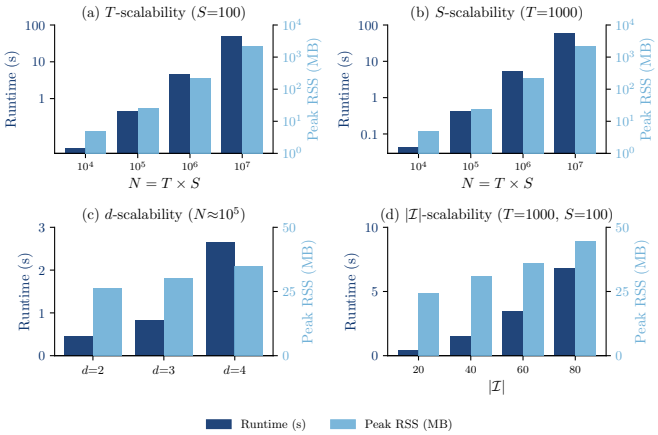


Fig. 3: EX-2：4 パラメータのスケーラビリティ（W=(24, 4)、θ=15、p_{item}=0.10）。濃青棒：計算時間（左軸）、水色棒：ピーク RSS（右軸）。

c) 得られた示唆.: Chicago Crime では ASSAULT + BATTERY がシカゴ南部・西部に慢性的な密集ウィンドウを形成し、3 種複合パターン（THEFT + CRIMINAL DAMAGE + BATTERY）により単独カテゴリ分析では見落とされる複合ホットスポットが特定された。NYPD Crime では重罪と軽犯罪の複合共起が区・週単位で把握され、NYC 311 では騒音苦情と違法駐車の複合パターンが住宅密集地区に繰り返し出現した。USGS Earthquake では深さ軸を含む 4 次元記述により、浅発地震と中深発地震を区別した密集パターンが識別された。いずれの事例でも、提案手法は「どのアイテムセットが、いつ・どこで密集するか」を具体的な時空間ウィンドウとして出力し、ドメイン専門家にとって解釈可能な分析結果を与えた。各データセットの詳細な事例は付録 Dに示す。

VI. 結論

本論文では、Apriori-Window [3] を任意の d 次元グリッドに拡張する **Multi-Dimensional Apriori-Window** を提案した。固定空間始点ごとの 1 次元マルチセット還元、重複考慮 t 軸ストライド、および $(k-1)$-部分集合区間マップ交差枝刈りの 3 技法により、全密集パターンとその任意形状の密集領域を厳密に列挙する。

実験により以下を示した：(1) 4 形状の合成データにおいて提案手法は厳密解を出力し、既存手法は F1 が最大 0.917、Jaccard が最大 0.190 にとどまった；(2) $N = 10^4$–10^8 で線形スケーリングを確認し、10^8 トランザクションを約 9 分で処理可能であった；(3) 犯罪・苦情・地震の d=3–4 実データにおいて、複合犯罪ホットスポットや地震の深さ別密集など、ドメイン知識と整合する解釈可能な示唆が得られた。

a) 制約と限界.: (1) 本手法はグリッド離散化を前提としており、ビン幅および $\boldsymbol{W}$ の選択が結果に影響する。実際には、$\boldsymbol{W}$ は対象とするパターンの時間的・空間的スケールに関するドメイン知識から初期化し、感度分析で検証することができる；θ は推定されたバックグラウンド頻度を基準に設定することが実用的である。(2) W_{sp}

や d が増加するとマルチセット構築の $O(N \cdot W_{\text{sp}})$ コストが増大し、高次元設定では次元削減や粗いビン化が必要となる。(3) 本手法は検出と記述に特化しており、因果的説明や外部イベントとの関連付けは対象外である。

b) 今後の課題.: (1) 適応的パラメータ選択：局所的なデータ統計量（密度分布、空間的自己相関）に基づき $\boldsymbol{W}$ と θ を自動調整するフレームワークは実用上重要である。(2) 更なる高速化：空間始点ごとの時間マルチセット構築が主要な計算ボトルネックである。累積和に基づく $O(1)$ ウィンドウ集約や、空間軸に沿った差分更新（スライス差分）による冗長計算の排除が有望である。

Acknowledgment

This work is supported by the Honda Bridge Project. The authors also acknowledge that portions of the text in this paper were generated with Anthropic's large language model Claude [26]. 実装は以下で公開している：https://github.com/kanatakayasu/Multi-Dimensional-Apriori-Window。

References

[1] R. Agrawal and R. Srikant, "Fast algorithms for mining association rules in large databases," in *Proceedings of VLDB*, 1994, pp. 487–499.

[2] J. Han, J. Pei, and Y. Yin, "Mining frequent patterns without candidate generation," *ACM SIGMOD Record*, vol. 29, no. 2, pp. 1–12, 2000.

[3] T. Takahashi, K. Takayasu, S. Suga, and S. Kurihara, "Exact mining of dense patterns via direct evaluation of local interval frequency using a sliding window," 2026.

[4] K. Shin, B. Hooi, and C. Faloutsos, "M-Zoom: Fast dense-block detection in tensors with quality guarantees," in *Proceedings of the European Conference on Machine Learning and Principles and Practice of Knowledge Discovery in Databases (ECML PKDD)*. Springer, 2016, pp. 264–280.

[5] L. Anselin, "Local indicators of spatial association—LISA," *Geographical Analysis*, vol. 27, no. 2, pp. 93–115, 1995.

[6] J. K. Ord and A. Getis, "Local spatial autocorrelation statistics: distributional issues and an application," *Geographical Analysis*, vol. 27, no. 4, pp. 286–306, 1995.

[7] M. Kulldorff, "A spatial scan statistic," *Communications in Statistics-Theory and Methods*, vol. 26, no. 6, pp. 1481–1496, 1997.

[8] D. Birant and A. Kut, "ST-DBSCAN: An algorithm for clustering spatial–temporal data," *Data & Knowledge Engineering*, vol. 60, no. 1, pp. 208–221, 2007.

[9] A. K. Mahanta, F. A. Mazarbhuiya, and H. K. Baruah, "Finding locally and periodically frequent sets and periodic association rules," in *Proc. PReMI*, 2005, pp. 576–582.

[10] P. Fournier-Viger, P. Yang, R. U. Kiran, S. Ventura, and J. M. Luna, "Mining local periodic patterns in a discrete sequence," *Information Sciences*, vol. 544, pp. 519–548, 2021.

[11] S. Shekhar and Y. Huang, "Discovering spatial co-location patterns: A summary of results," in *Advances in Spatial and Temporal Databases (SSTD)*, ser. LNCS, vol. 2121. Springer, 2001, pp. 236–256.

[12] F. Qian, L. Yin, Q. He, and J. He, "Mining spatio-temporal co-location patterns with weighted sliding window," in *2009 IEEE International Conference on Intelligent Computing and Intelligent Systems (ICICISYS)*, vol. 3. IEEE, 2009, pp. 181–185.

[13] M. Jiang, A. Beutel, P. Cui, B. Hooi, S. Yang, and C. Faloutsos, "CrossSpot: A general suspiciousness metric for dense blocks in multimodal data," in *Proceedings of the 2015 IEEE International Conference on Data Mining (ICDM)*. IEEE, 2015, pp. 781–786.

[14] K. Shin, B. Hooi, and C. Faloutsos, "Fast, accurate and flexible algorithms for dense subtensor mining," *ACM Transactions on Knowledge Discovery from Data (TKDD)*, vol. 12, no. 3, pp. 28:1–28:30, 2018.

[15] K. Shin, B. Hooi, J. Kim, and C. Faloutsos, "D-cube: Dense-block detection in terabyte-scale tensors," in *Proceedings of WSDM*, 2017, pp. 681–689.

[16] K. Shin, B. Hooi, J. Kim, and C. Faloutsos, "Densealert: Incremental dense-subtensor detection in tensor streams," in *Proceedings of KDD*, 2017, pp. 1057–1066.

[17] W. Feng, S. Liu, and X. Cheng, "CatchCore: Catching hierarchical dense subtensor," in *Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*. Springer, 2020, pp. 156–172.

[18] W. Feng, S. Liu, D. Koutra, H. Shen, and X. Cheng, "SpecGreedy: Unified dense subgraph detection," in *Joint European Conference on Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*. Springer, 2020, pp. 181–197.

[19] M. Kulldorff, "Prospective time periodic geographical disease surveillance using a scan statistic," *Journal of the Royal Statistical Society: Series A*, vol. 164, no. 1, pp. 61–72, 2001.

[20] T. Tango and K. Takahashi, "A flexibly shaped spatial scan statistic for detecting clusters," *International Journal of Health Geographics*, vol. 4, no. 1, p. 11, 2005.

[21] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, "A density-based algorithm for discovering clusters in large spatial databases with noise," in *Proceedings of KDD*, 1996, pp. 226–231.

[22] City of Chicago, "Crimes – 2001 to present," Chicago Data Portal. https://data.cityofchicago.org/Public-Safety/Crimes-2001-to-Present/ijzp-q8t2, 2024, accessed 2026.
[23] New York City Police Department, "NYPD complaint data historic," NYC Open Data. https://data.cityofnewyork.us/Public-Safety/NYPD-Complaint-Data-Historic/qgea-i56i, 2024, accessed 2026.
[24] NYC Office of Technology and Innovation, "311 service requests from 2020 to present," NYC Open Data. https://data.cityofnewyork.us/Social-Services/311-Service-Requests-from-2010-to-Present/erm2-nwe9, 2024, accessed 2026.
[25] U.S. Geological Survey, "USGS earthquake catalog (ComCat)," https://earthquake.usgs.gov/earthquakes/search/, 2021, m2.5+, 2000–2020, accessed 2026.
[26] Anthropic, "Claude," https://claude.ai, 2025, accessed: 2026.

Appendix A
補題の証明

Proof of Lemma 1. 任意のトランザクション n について、$P \subseteq d_n$ ならば $Q \subseteq d_n$ である。したがって、任意の固定空間始点ベクトル $\boldsymbol{s}_{\mathrm{sp}}$ に対し、$L_P(\boldsymbol{s}_{\mathrm{sp}})$ の各要素は $L_Q(\boldsymbol{s}_{\mathrm{sp}})$ にも含まれる。ゆえに、任意の s_0 について $S_P(s_0, \boldsymbol{s}_{\mathrm{sp}}) \leq S_Q(s_0, \boldsymbol{s}_{\mathrm{sp}})$ が成り立つ。 □

Proof of Lemma 2. 現在のウィンドウ $[l, l+W_0]$ 内の右端 θ 個のイベントを考える。その最左のイベントは $L[l_{\mathrm{lo}} + (c-\theta)] = l_{\mathrm{dense}}$ である。任意の $l' \leq l_{\mathrm{dense}}$ について、全 θ 個のイベントは $\geq l'$ であり、$l' \geq l$ より $l'+W_0 \geq l+W_0$ が成り立つ。したがって、これらのイベントは現在のウィンドウ $[l, l+W_0]$ から外れず、$[l', l'+W_0]$ にもすべて含まれる。ゆえに、l' においてもウィンドウ内に少なくとも θ 個のイベントが存在する。 □

Appendix B
EX-1 合成データ生成の詳細

a) 背景データ生成.: T=100 × S=100 のグリッド上の全格子点に 1 トランザクションを配置する。アイテム数 $|\mathcal{I}|$=40、各セルで各アイテムを Bernoulli(p_{item}=0.15) で独立にサンプリングし背景トランザクションを構成する。全アイテムが不在のセルにはデフォルトでアイテム 1 を割り当てる。

b) パターン埋め込み.: GT パターン $P_k = \{2k-1, 2k\}$（$k = 1, \ldots, 20$）を空間帯 $s \in [5(k-1),\ 5(k-1)+4]$（幅 5 セル）に割り当てる。各埋め込み形状の定義する帯内セルに対して、独立に Bernoulli(p_{embed}=0.25) でアイテム対 P_k を同時出現させる。

c) 埋め込み形状.: 各形状はパターン P_k の空間帯内での時空間的分布を規定する（帯の開始位置 $b_s = 5(k-1)$、終端 $b_e = b_s + 4$）。

- **Shape A（矩形）**: $t \in [30, 70]$、$s \in [b_s, b_e]$ の全セルに一様に埋め込む。時刻・空間ともに固定された最もシンプルな矩形領域。
- **Shape B（ドリフト）**: $t \in [30, 70]$ の各時刻 t において、空間中心 $s_c = \lfloor b_s + (t-30)/40 \cdot 2 \rfloor$（$b_s$ から b_s+2 へ線形移動）を中心に幅 5 セルの帯を配置する。時刻とともに密集帯が空間軸を滑らかに移動する。
- **Shape C（断続）**: $t \in [15, 35] \cup [65, 85]$、$s \in [b_s, b_e]$。同一空間帯に 2 つの独立した時間区間で密集が発生する。
- **Shape D（拡大）**: $t \in [30, 40]$: 空間中心 b_s+2 の 1 セル（幅 1）；$t \in [41, 55]$: $s \in [b_s+1, b_e-1]$（幅 3）；$t \in [56, 70]$: $s \in [b_s, b_e]$（幅 5）。時間が進むにつれて空間幅が段階的に拡大する。

d) 評価設定.: 各形状につき乱数シード 3 種（seed $\in \{42, 55, 68\}$）でデータを生成し、計 $4 \times 3 = 12$ データセットで評価する。提案手法のパラメータは $W = (20, 5)$、$\theta = 30$ で全形状共通とした。比較手法のパラメータ範囲は Table IIIの通りグリッドサーチにより決定した。

TABLE III: EX-1 比較手法のグリッドサーチパラメータ範囲。

手法	グリッドサーチ対象
Colocation	PI 閾値 $\tau \in \{0.05, 0.07, \ldots, 0.49\}$（23 値）
STCP-Miner	PI 閾値（同上）× ウィンドウ幅 $W_t \in \{4, 13, 26, 54\}$
MZoom	Top ブロック数 $k \in \{1, 2, 3, 5\}$
ST-DBSCAN	$\varepsilon_1 \in \{1, 2, 3\}$、$\varepsilon_2 \in \{3, 7, 15\}$、min_pts $\in \{2, 5\}$

Appendix C
EX-2 合成データ生成の詳細

EX-2 では、$d = 2$ のグリッド $\{0, \ldots, T-1\} \times \{0, \ldots, S-1\}$ の **全**格子点に 1 トランザクションを配置して合成データを生成する。各トランザクションについて、語彙サイズ $|\mathcal{I}| = 20$、背景出現確率 $p_{\mathrm{item}} = 0.10$ のもと、各アイテムを独立に Bernoulli(p_{item}) からサンプリングする。全アイテムが不在のセルにはデフォルトでアイテム 1 を割り当て、各セルに正確に 1 トランザクションが存在することを保証する。これによりトランザクション数は正確に $N = T \times S$ となる。

埋め込みパターンは注入しない。密集パターンは Bernoulli 背景の統計的揺らぎから自然に生じる。予備的な校正により、全構成で閾値 $\theta = 15$ において十分な数のパターンが検出されることを確認した。

§V-Bで述べた通り、d 次元グリッドにおける d の増加に伴う $N = T \times S^{d-1}$ の成長は N スケーラビリティに吸収されるため、次元数に関する別途のスケーラビリティ実験は不要である。

Appendix D
実データセットの詳細

a) データセット概要.: EX-3（§V-C）で使用した 4 つの実データセットの詳細を示す。

- **Chicago Crime** [22]: シカゴ市が公開する犯罪報告データ。日時・緯度・経度・犯罪種別（33 種）を含む。時間を週単位、緯度・経度をそれぞれ 0.02° 等幅ビンに離散化した（グリッドサイズ $261 \times 20 \times 21$）。
- **NYPD Crime** [23]: ニューヨーク市警察が公開する犯罪報告データ。犯罪種別（69 種）を含む。週単位・0.02° 空間ビン（グリッドサイズ $261 \times 43 \times 57$）。
- **NYC 311** [24]: ニューヨーク市の市民苦情（311）データ。苦情種別（232 種）を含む。週単位・0.02° 空間ビン（グリッドサイズ $261 \times 43 \times 57$）。
- **USGS Earthquake** [25]: 米国地質調査所が公開する地震カタログ。マグニチュードを 5 段階に離散化してアイテムとした。本データセットのみ 4 次元（時間 × 緯度 × 経度 × 深さ）で、グリッドサイズ $1{,}096 \times 20 \times 20 \times 4$。

b) 実験パラメータ.: 全データセットで最大パターン長 $|P| \leq 3$ とした。3 次元データセット（Chicago/NYPD/NYC 311）は時間ウィンドウ $W_0 = 4$ 週・空間ウィンドウ $W_k = 3$ ビン（$k = 1, 2$）を共通とし、

TABLE IV: 実験データセット。N: トランザクション数(非空セル数)、#Items: アイテム種類数、avgℓ: トランザクションあたり平均アイテム数、d: 次元数。

Dataset	N	#Items	avgℓ	d
Chicago Crime [22]	47,217	33	7.59	3
NYPD Crime [23]	189,481	69	5.67	3
NYC 311 [24]	135,490	232	18.14	3
USGS Earthquake [25]	13,151	5	1.17	4

閾値 θ のみ調整した。USGS Earthquake は $W_0 = 13$ 週・$W_k = 2$ ビン（$k = 1, 2, 3$）、$\theta = 2$ とした。

c) 分析結果.*:* Table Vに各データセットの検出パターン数と実行時間を示す。パターン数はアイテム語彙サイズに応じて増加し、実行時間はデータ規模と語彙に比例して 0.5–108.7 秒の範囲にある。以下に各データセットの詳細な分析を示す。

TABLE V: 実データにおける提案手法の検出結果。θ: 密集閾値、合計: 全サイズのパターン数、time: 実行時間(秒)。

Dataset	W	θ	合計	time (s)
Chicago Crime	$(4, 3, 3)$	3	2,835	9.7
NYPD Crime	$(4, 3, 3)$	5	4,478	38.2
NYC 311	$(4, 3, 3)$	35	5,130	108.7
USGS Earthq.	$(13, 2, 2, 2)$	2	18	0.5

Chicago Crime. 約 5 年（261 週）・シカゴ全域を対象とした 3 次元グリッド解析で 33 種の犯罪カテゴリに対し 2,835 パターンを検出した。ASSAULT + BATTERY（暴行・傷害）のペアはシカゴ南部・西部の複数地区に 4 週 ×3 ビン ×3 ビンの密集ウィンドウを形成し、年間を通じた慢性的な犯罪集中を記述する。THEFT + CRIMINAL DAMAGE（窃盗・器物損壊）の対は商業地区・市街地に多く、週単位の密集として現れる。さらに THEFT + CRIMINAL DAMAGE + BATTERY のような 3 種複合パターンは、複数の犯罪種が同一時空間ウィンドウに同時集中する高犯罪密度の地域・期間を精密に特定し、より広い単独カテゴリ分析では見落とされがちな複合的ホットスポットを浮き彫りにする。

NYPD Crime. ニューヨーク市全域の約 5 年分のデータで 69 種の犯罪カテゴリに対し 4,478 パターンを検出した。シカゴ（33 種）より語彙が多いため検出パターン数も増加し、重罪（Felony Assault、Robbery など）と軽犯罪（Petit Larceny、Criminal Mischief など）の複合共起を区（borough）・週単位で詳細に把握できる。個々の犯罪種は低頻度であっても、特定の街区・時期に組み合わせとして局所集中するパターンが多数存在し、単純な発生頻度ランキングでは検出できない複合的な治安構造を提案手法は明示的に記述する。

NYC 311. 232 種という最大語彙の苦情カテゴリに対し 5,130 パターン（最多）を検出した。Noise – Residential や Noise – Street/Sidewalk と Illegal Parking の組み合わせは、住宅密集地区の特定週に繰り返し密集ウィンドウを形成し、生活環境の複合的悪化を示す。夏季には建設騒音・ゴミ収集問題・路上駐車苦情の 3 種複合パターンが特定地区で増加する傾向が見られ、季節性の複合問題を捉えることができる。語彙が 232 種と大きいため単独苦情の頻度分析では埋もれる共起パターンが多く、時空間的絞り込みにより区・週レベルの施策立案への活用が期待される。

USGS Earthquake. 約 21 年（1,096 週）の地震カタログを時間 × 緯度 × 経度 × 深さの 4 次元グリッドで解析し、5 マグニチュードバンドに対して 18 パターンを検出した。M3.0–4.0 + M4.0–5.0 の共起パターンは、特定の緯度・経度・深さ・期間のウィンドウに複数マグニチュード帯の地震が密集する状況を示し、本震後の余震シーケンスや群発地震活動の典型的な特徴と整合する。深さ軸を含む 4 次元記述により、浅発地震（地殻内）と中深発地震（スラブ内）を区別した密集パターンが識別可能で、断層種類や沈み込み帯の構造的特徴との対応が示唆される。アイテム語彙が 5 種と最小であるため計算量は低く、4 次元の高次元設定においても提案手法が実時間で動作することを示す。