Multi-Dimensional Apriori-Window

多次元トランザクションデータにおける
密集アイテムセット領域の厳密抽出

研究紹介　高安奏多

分析者が本当に欲しい答え

大規模小売・疫学・物流データで知りたいこと：

※ アイテムセット＝一緒に買われた商品の組み合わせ（例：{ビール, ポテトチップス}）

何が
アイテムセット P

＋

いつ・どこで
密集領域 R(P)

例：「**ビールとポテトチップス**は**週46〜52・都市部店舗**で集中購買」

→ 地域・時期に特化した在庫計画やプロモーションに直結

パターン P だけでは「どこに追加発注？」が不明

領域 R だけでは「何を発注？」が特定できない

両方が揃って初めて施策を立案できる

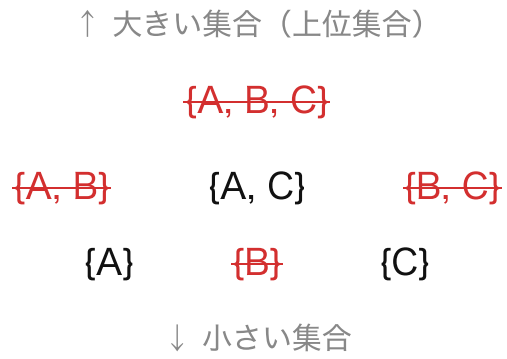
既存手法の限界

手法カテゴリ	アイテムセット列挙	時空間密集領域	領域形状
Apriori / FP-Growth	○	×	—
LPFIM / LPPM	○	1Dのみ	区間
Apriori-Window（1D）	○	1Dのみ	区間
MZoom（密テンソル）	△	○	直積のみ
LISA / ST-DBSCAN	×	○	任意
本手法（提案）	○	○	**任意**

パターン列挙と多次元密集領域抽出を同時に達成する手法がない

Apriori 特性（反単調性）

「頻出でないアイテムセットの上位集合も頻出でない」



例：{B} が非頻出 → {B}を含む上位集合 {A,B}, {B,C}, {A,B,C} をすべて**枝刈り**

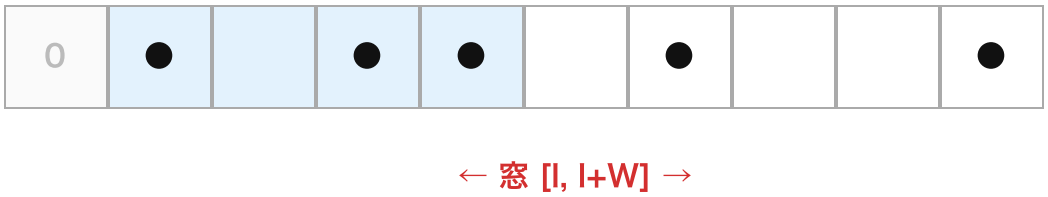
なぜ重要か？

- アイテムが10個なら組み合わせは1,024通り、20個なら約100万通りと**指数的に爆発**
- 反単調性により、非頻出パターンの**上位集合を丸ごとスキップ**できる
- 本手法ではこの性質を、次スライドで説明する**ウィンドウ内の出現数**にも適用

基盤：1D Apriori-Window の仕組み

核心アイデア：スライディング窓で局所サポートを直接計算

時刻列上のパターン P の出現（●）に窓幅 W のウィンドウをスライド：



- **区間サポート**：sup(P, l, W) = 窓 [l, l+W] 内の P の出現数
- sup(P, l, W) ≥ θ なら、その窓位置 l は**「密集開始点」**
- 密集開始点の連続区間 [a, b] → **密集区間 [a, b+W]**

前スライドの**Apriori 特性**がここでも成立：部分集合が密集でなければ、親集合も密集でない

→ **Apriori 枝刈り**で候補空間を大幅削減

1Dの限界 → 多次元化の必要性

1D：時間軸のみ



「**いつ**密集？」→ 答えられる

「**どこで**密集？」→ 答えられない

→

多次元：時間 × 空間

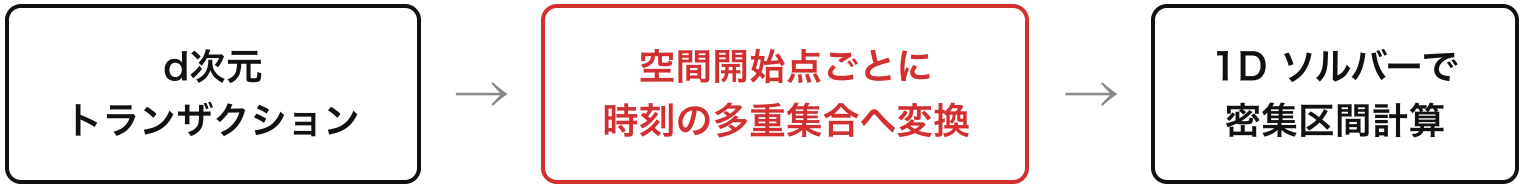
「**いつ・どこで**密集？」に答える

課題：多次元に拡張すると…

- 同一時刻に**複数トランザクション**が存在（重複タイムスタンプ）
- 空間開始点の組み合わせ爆発

提案：多次元 Apriori-Window

核心：**d 次元問題を「固定空間開始点ごとの 1D 問題」に還元**



3つの技法

- **1D 還元**：空間の位置を固定して、時間方向だけの問題に分解する
- **部分集合の密集区間で枝刈り**：小さいアイテムセットの結果を使い、候補を絞り込む（Apriori 枝刈り）
- **重複タイムスタンプの一括処理**：同じ時刻のデータをまとめて効率的に処理

多次元化しても本質的に解いているのは**「重複を許す 1D Apriori-Window」**

実験結果ハイライト

合成データ比較（EX-1）

F1＝パターンの検出精度、Jaccard＝領域の一致度（1.00 が完全一致）

	提案手法	既存最良
パターン検出 F1	**1.00**	0.917
領域復元 Jaccard	**1.00**	0.190

※ 提案手法は定義の厳密解を出力するため F1 = Jaccard = 1.00

スケーラビリティ（EX-2）

- N に対して**線形スケーリング**
- 10^8 トランザクション → **約12分**で処理

実データ適用（EX-3）

- **犯罪**（Chicago, NYPD）
  → 複合犯罪ホットスポットを特定
- **市民苦情**（NYC 311）
  → 騒音+違法駐車の複合パターン
- **地震**（USGS, d=4）
  → 深さ別の密集パターンを識別

いずれも**ドメイン知識と整合**する解釈可能な結果

まとめ

貢献

- **多次元 Apriori-Window** を提案：パターン列挙と密集領域抽出を同時に達成する初の手法
- 固定空間開始点ごとの **1D 還元**により、多次元でも厳密解を保証
- 10^8 規模のデータに対する**線形スケーラビリティ**を実証

今後の課題

- W と θ の**適応的パラメータ選択**
- 累積和・差分更新による**更なる高速化**