スライディング窓による区間局所頻度の直接評価を用いた密集パタンの厳密抽出

著者名（投稿時に記入）

概要

特定の時間区間でのみ高頻度に出現するパタンとその密集区間を正確に抽出することは，季節的な需要の把握や異常行動の検出など多くの応用で重要である．頻出アイテムセットマイニングはデータセット全体のサポートを基準とするため，局所的に密集したパタンを検出できない．既存の区間付き密集パタン抽出手法は出現間隔に基づく制約によって密集区間を推定するが，出現間隔制約パラメータがパタン同定精度と区間検出精度の両方を支配するため，両者を同時に高く保つパラメータ設定は困難である．本稿では，この構造的な限界を解消する厳密解法 Apriori-window を提案する．提案手法はスライディング窓により局所頻度を直接評価するため出現間隔制約パラメータを必要とせず，また反単調性を利用した探索空間の削減と，余剰出現に基づくスライディング窓のスキャン数削減により，正確かつ効率的に密集区間を列挙する．3 つの実データセットを用いた実験では，既存手法がパタン同定と密集区間の検出を精度良く両立することが困難であることを示し，合成データによるスケーラビリティ実験により提案手法の実用性を確認した．

キーワード：密集パタンマイニング，頻出パタンマイニング，時系列

1　はじめに

小売・医療・サイバーセキュリティをはじめとする多様な分野で，日々大量のデータが蓄積されている．流行り廃りや季節的なトレンド，外部のイベントの影響等によってデータの記録される内容は時間とともに変動する．そうしたデータ内にある時間的な特徴を抽出することはデータの性質を理解するうえで重要である。パタンマイニングではデータから有益な情報を抽出する多数の手法が提案されている．頻出アイテムセットマイニング [1–3] はパタンマイニングの代表的な手法であり，データ全体に頻出するアイテムの組み合わせをパタンとして抽出する．しかし，この手法はデータセット全体に対するサポートを基準とするため，局所的な出現頻度を考慮できないという問題を抱える．そのため，最小サポートを高く設定すれば全体では限定的な区間に密集したパタンが除外され，低く設定すれば密集していない多数のパタンとともに抽出される．このジレンマは rare item problem [7] として知られている．

この問題に対処するため，特定の区間内でのみ高い出現頻度を示す密集パタンとその密集区間を同時に抽出する手法が提案されてきた．LPFIM [34], LPPM [35], RPM [36] はいずれも出現間隔に基づくパラメータを通じて密集区間を推定し，パタンとその区間を同時に出力する．しかし，これらの手法では出現間隔ベースのパラメータがパタン同定精度と区間検出精度の両方を支配するため，両者を同時に高く保つよう適切なパラメータを設定することは極めて困難である．

本稿では，この限界を解消した厳密解法，Apriori-window を提案する．提案手法は，スライディング窓内の出現回数を直接計算することで局所頻度を評価するため，ギャップ閾値を必要とせず，パラメータ感度の問題を回避できる．また反単調性に基づくパタン候補と候補区間の枝刈りおよびストライド調整による効率化を組み合わせることで，実用的な実行時間で網羅的な厳密抽出を実現する．

本稿では以下の研究上の問いに答える：

RQ1　密集パタンの同定と密集区間の検出を厳密に行う解法は実現可能か？

RQ2　既存手法は密集するパタンの同定と密集区間の検出を精度良く行えるか？

RQ3　密集パタンの厳密解法はデータの性質に対して時間・メモリ使用量がどのように増加するか？

本稿の主な貢献は以下の通りである：

1. スライディング窓による局所頻度の直接評価に基づく厳密解法 Apriori-window を提案する．反単調性およびスライディング窓のスキップメカニズムの安全性を証明し抽出結果の厳密性を示す（RQ1）．
2. 3 つの実データセットにおける既存手法のパラメータ走査により，既存手法が，高精度な密集パタンの同定と密集区間の検出の両立が困難であることを示す（RQ2）．
3. 合成データによるスケーラビリティ実験でデータ特性に対する実行時間・メモリの増大特性を定量化し，提案手法の実用性を検証する（RQ3）．

2　関連研究

2.1　頻出アイテムセットマイニング

頻出アイテムセットマイニング（Frequent Itemset Mining; FIM）は，データセット全体におけるサポートがユーザ指定の閾値以上であるアイテムセットを発見するタスクである [41]．Apriori [1] は反単調性を利用した候補生成・枝刈りの枠組みを提案し，ECLAT [2] は垂直データ表現により効率を改善し，FP-Growth [3] は候補生成を排除した圧縮木構造による高速化を実現した．これらの基盤的手法とその発展については [4–6] にサーベイがある．

FIM の枠組みに対しては，評価指標の拡張として頻度に代わり利益等の効用値を用いる高効用アイテムセットマイニング [8, 9] がある．また，パタンマイニングの計算効率やパタン品質の向上を目的として，オートエンコーダによるルールの直接抽出 [10, 11]，二値化ニューラルネットワークによる冗長性の低いパタンセットの発見 [12]，強化学習による適応的な探索 [13]，深層学習による逐次パタンや高効用パタンの抽出 [14, 15]，進化計算による近似的探索 [16, 17] 等が提案されている．

これらの手法はいずれもサポートをデータセット全体で評価するため，特定の時間区間でのみ高頻度に出現するアイテムセットを検出できない．全体では低頻度だが局所的に高頻度なパタンは，最小サポートを高く設定すれば見逃され，低く設定すれば非密集パタンが大量に混在する（rare item problem [7]）．深層学習系手法はスケーラビリティやルール数削減に貢献するが，サポート評価の枠組みは FIM と同一であり，加えて潜在表現に基づく近似的な結果は厳密な網羅的抽出を保証しない．

2.2　時間情報を考慮したパタンマイニング

データセット全体ではなく，時間軸に沿った頻度の変化を考慮する手法が提案されている．TP-Mine [18] は頻度が劇的に変化する時点を検出する transitional pattern を扱うが，出力は変化点であり区間ではない．SPF [19] は各アイテムの展示期間に基づいて正規化した頻度計算を行い，同一アイテムの比較可能なサポートを提供する．PPM [20] はカレンダーベースの固定粒度で分割した区間ごとにサポートを評価する時間相関ルールマイニング手法であり，パタンの時間的変化の把握に有用だが，区間がカレンダー粒度に固定される．

バースト検出 [21, 22] は単一イベントの出現頻度が急増する区間を同定する手法であり，「特定区間での頻度集中」を検出する点で密集パタンと問題意識を共有するが，アイテムセットの組合せ的探索を伴わない点で本研究とは異なる．

周期的パタンマイニングの分野では，周期的頻出パタン (Periodic-Frequent Pattern; PFP) [23–27] が提案されている．これらの手法では，データ全体のアイテムセットの出現回数の下限に加え，データ内でのアイテムセット X の出現間隔列を $p_1, p_2, \ldots$ とすると，最大周期 $Per(X) = \max_i p_i$ として，$Sup(X) \geq minSup$ かつ $Per(X) \leq maxPer$ を満たすアイテムセットが出力される．$maxPer$ はすべての出現間隔に課す上限であり，値が小さいほど厳

密な周期性が要求され, 1 つでも間隔が大きい出現があると全体が棄却されるため, ノイズに脆弱である. 部分周期的頻出パタン (Partial Periodic-Frequent Pattern; PPFP) [28] はこの制約を緩和し，周期比 $PR(X) = |\{p_i \leq maxPer\}|/(|Sup(X)|+1)$ が $minPR$ 以上であるアイテムセットと定義される. $minPR$ はあるアイテムセット X の全出現間隔のうち $maxPer$ 以内の間隔が占める必要割合を制御し，値を下げると不規則な周期を持つパタンも検出できる. ただし両手法はパタンのみを出力し，密集区間の明示的な出力は行わない.

エピソードマイニング [29] は複数のイベント間の時間的関係性を含む逐次パタンを扱い，イベントの出現頻度に基づく周期性を捉えるが，アイテムセットとその密集区間の同時出力という問題設定とは異なる. また，新興パタンマイニング [30] はデータ分布の変化前後でサポートが大きく変化するパタンを発見するが，密集区間の出力には対応しない.

2.3 パタンとその密集区間を出力する手法

密集パタン抽出には，パタンだけでなくそれが密集する区間も同時に出力することが重要である. 既存の区間を抽出する手法は密集度の評価方法により，局所頻度を直接計算するアプローチと，出現間隔の制約に基づくアプローチに大別される.

局所頻度を直接計算するアプローチとして, GLFMiner [31] はローカル頻出パタンとその区間を自動的に抽出するが，区間が事前定義された時間粒度の整数倍に固定されるため，データ駆動の柔軟な区間検出ができない. SIM [32, 33] は各アイテムセットに対し頻度条件を満たす最適な期間を出力する. 動機は密集パタンと近いが，各アイテムセットに対し最適な単一期間を出力する点，最小区間長の制約がない点で，密集区間の網羅的な列挙を目的とする本研究とは問題設定が異なる.

出現間隔ベースのアプローチとして, LPFIM [34] は局所的に頻出するアイテムセットとその区間を抽出する. あるアイテムセット X について，出現時点間隔が $minthd1$ 以上になったとき新たな区間を開始し，σ を最小局所サポート比率，tc を区間内トランザクション数として，各区間の局所サポート $Sup_{[t_1,t_2]}(X)/tc_{[t_1,t_2]} \geq \sigma$ かつ区間長 $\geq minthd2$ である区間を出力する. $minthd1$ は区間の分割粒度を決定，大きいほど連続出現をまとめて長い区間を生成し，$minthd2$ は短すぎる区間を除去する.

LPPM [35] は 出現間隔制約に対する余剰累積 $spillover$ を導入することによりノイズに頑健な区間検出を実現する. 出現タイムスタンプ ts_i における余剰 $surPer(ts_i) = interval(ts_i) - maxPer$ を累積し，$soPer(ts_i) = \max(0,\ soPer(ts_{i-1}) + surPer(ts_i))$ が $maxSoPer$ を超えた時点を区間の終端とする. 長さ $\geq$ minDur の区間がパタンとともに出力される. $maxPer$ は許容する出現間隔の上限，$maxSoPer$ は許容する出現間隔の超過総量，$minDur$ は区間の最小長を制御する.

RPM [36] は，出現間隔が $maxPer$ 以下である区間を周期区間として分割し，周期区間内の連続出現回数が $minPS$ 以上である周期区間の数が $minRec$ 以上であるアイテムセットをとして出力する. $maxPer$　は周期的とみなす出現間隔の上限，$minPS$ は 1 区間内の最小連続出現数，$minRec$ は周期区間が現れる最小個数を制御する.

これらの手法はパタンとその区間の両方を出力する点で本研究に最も近い先行研究である. 各手法のパタン定義と本研究の密集パタン定義との比較を Table 1 に示す. Apriori-window は窓内の出現数を直接評価するのに対し，既存手法はギャップ制約・余剰累積・周期閾値といったパラメータを通じて密集度を間接的に推定する点が異なる.

2.4 スライディング窓による局所頻度の評価

スライディング窓 [37, 38] はストリームマイニング [40] や時系列の変化点検出 [39] に用いられている. ストリームマイニングでは，オンラインで追加されるデータに対し分析対象とする時間範囲を限定する枠組みとして窓が機能しており，変化点検出ではデータの局所的な統計量の変化を検出する手段として用いられる.

密集パタンの本質は，あるアイテムセットが特定の連続区間において局所的に高い頻度で出現することにある. 本研究ではスライディング窓による連続区間内での局所頻度の評価を導入する. 窓を移動さ

表 1　各手法のパタン定義と 本研究 との比較.

パタン名	パタン条件	密集区間の検出方法	出力
Periodic-Frequent Pattern	• $Sup(X) \geq minSup$：全体出現回数の下限 • $Per(X) = \max_i p_i \leq maxPer$：連続出現間の時刻差の最大値の上限	区間を出力しない	P のみ
Partial Periodic-Frequent Pattern	• $Sup(X) \geq minSup$：全体出現回数の下限 • $PR(X) \geq minPR$：出現間隔のうち $maxPer$ 以内の割合の下限	区間を出力しない	P のみ
Locally and Periodically Frequent Itemset	• $Sup_{[t_1,t_2]}(X)/t_c \geq \sigma_\ell$：区間 $[t_1, t_2]$ 内の局所サポート率（t_c は区間長）の下限 • $t_c \geq minthd2$：区間の最小長	出現間隔が $minthd1$ 以上になった時点で区間を分割する	P + 区間リスト
Local Periodic Pattern	• $spillover_{[t_1,t_2]} \leq maxSoPer$：$maxPer$ を超えた出現間隔の累積余剰量の上限 • $t_c \geq minDur$：区間の最小長	累積余剰量が $maxSoPer$ を超えた時点で区間を終端とする	P + 区間リスト
Recurring Pattern	• $rec(X) \geq minRec$：検出される再帰区間数の下限 • $ps(X) \geq minPS$：各再帰区間内の出現密度の下限	出現間隔が $maxPer$ 以内の連続出現をひとまとめにして 1 区間とする	P + 区間リスト
Dense Pattern (Ours)	• $\sup(P, l, W) \geq \sigma$：窓 $[l, l+W]$ 内の直接出現回数の下限	スライディング窓内で出現頻度の条件を満たすかを判定する	P + 区間リスト

せながら内部の出現頻度を直接計算することで，出現間隔の制約を介さずに局所的な密集度を評価でき，原理的にパラメータ感度の問題を回避できる．これは変化点検出に用いる関連研究と似た着想である．しかし，筆者らの調査した範囲では，スライディング窓による局所頻度の直接評価を Apriori の反単調性と組み合わせ，アイテムセットとその密集区間を網羅的に抽出することを主目的とした先行研究は確認できなかった．本研究は，この方向をアルゴリズムとして定式化・実装する試みである．

3　問題定義

3.1　基本定義

定義 1 (タイムスタンプ付きトランザクションデータベース)**.** アイテム全体集合 $\mathcal{I}$ 上のタイムスタンプ付きトランザクションデータベースを $D = \{(T_t, t) \mid t \in \mathbb{Z}_{\geq 0}\}$ の有限集合とする．ここで各 $T_t \subseteq \mathcal{I}$ はタイムスタンプ t に対応するトランザクションである．

表 2　具体例に用いるトランザクションデータベース D

タイムスタンプ t	トランザクション T_t
1	$\{a, b\}$
3	$\{a, b, c\}$
5	$\{b, c\}$
7	$\{a, b, c\}$
9	$\{a, b\}$
20	$\{a, b, c\}$
22	$\{b, c\}$
25	$\{a, b, c\}$

例. 以降の説明を通じて, Table 2 に示すデータベース D（$\mathcal{I} = \{a, b, c\}$，$W = 10$，$\sigma = 3$）を用いる．

定義 2 (出現タイムスタンプ列)**.** アイテムセット $P \subseteq \mathcal{I}$ の D における出現タイムスタンプ列を $occ(P, D) = \{t \mid P \subseteq T_t, (T_t, t) \in D\}$ と定義する．D が文脈から明らかな場合は $occ(P)$ と略記する．

例．Table 2 における各アイテムセットの出現タイ

ムスタンプ列は以下の通りである：

$$
\begin{aligned}
occ(\{a\}) &= \{1,3,7,9,20,25\}\\
occ(\{b\}) &= \{1,3,5,7,9,20,22,25\}\\
occ(\{c\}) &= \{3,5,7,20,22,25\}\\
occ(\{a,b\}) &= \{1,3,7,9,20,25\}\\
occ(\{a,c\}) &= \{3,7,20,25\}\\
occ(\{b,c\}) &= \{3,5,7,20,22,25\}\\
occ(\{a,b,c\}) &= \{3,7,20,25\}
\end{aligned}
$$

定義 3 (区間サポート)．アイテムセット P の窓 $[l, l+W]$（$W > 0$：窓サイズ）における区間サポートを

$$sup(P, l, W) = |\{t \in occ(P) \mid l \le t \le l+W\}|$$

と定義する．最小サポート $\sigma \in \mathbb{Z}_{>0}$ に対し，$sup(P,l,W) \ge \sigma$ を満たすとき，窓 $[l,l+W]$ を P の密集窓と呼ぶ．

例．$P = \{a,b\}$，$l = 1$，$W = 10$ のとき，

$$sup(\{a,b\},1,10) = |\{1,3,7,9\}| = 4 \ge 3 = \sigma$$

であるから窓 $[1,11]$ は $\{a,b\}$ の密集窓である．一方 $l = 15$ では $sup(\{a,b\},15,10) = |\{20,25\}| = 2 < 3$ であり密集窓ではない．

定義 4 (密集区間)．区間 $[s,e]$（$0 \le s$，$e \le T_{\max}$，$e - s \ge W$）が P の密集区間であるとは，

$$\forall l \in \big\{t \in occ(P) \mid s \le t \le e{-}W\big\}:\ sup(P,l,W) \ge \sigma$$

かつ当該区間がこれ以上拡張できないものとする．ここで $T_{\max}$ はデータセット D の最大タイムスタンプである．

例．$P = \{a,b\}$ について $occ(\{a,b\}) = \{1,3,7,9,20,25\}$ に対し，$sup(\{a,b\},l,10) \ge 3$ が成り立つのは $l \in [-3,3]$ のみである．実際 $l = 4$ のときの区間サポートは $sup(\{a,b\},4,10) = |\{7,9\}| = 2 < 3$ となる．よって密集区間の右端点は $e = 3 + 10 = 13$ となり，左端を 0 以上に制約すると $\{a,b\}$ の密集区間は $[0,13]$ である．

定義 5 (密集パタン)．*1* つ以上の密集区間を持つアイテムセット P を密集パタンと呼ぶ．

定義 6 (密集パタン抽出問題)．タイムスタンプ付きトランザクションデータベース D, 窓サイズ W, 最小サポート σ が与えられたとき，すべての密集パタン P とその密集区間の集合 $DI(P)$ の組 $(P, DI(P))$ を網羅的に列挙する．

例．Table 2 の D，$W = 10$，$\sigma = 3$，$T_{\max} = 25$ に対する全密集パタンとその密集区間を以下に示す：

$$
\begin{aligned}
\{a\}&:\ [0,13]\\
\{b\}&:\ [0,15],\ [15,25]\\
\{c\}&:\ [0,13],\ [15,25]\\
\{a,b\}&:\ [0,13]\\
\{b,c\}&:\ [0,13],\ [15,25]
\end{aligned}
$$

4 提案手法：Apriori-window

4.1 手法の概要

Apriori-window は，Apriori の反単調性 [1] をスライディング窓局所頻度評価に適用した厳密解法である．入力はタイムスタンプ付きトランザクションデータベース D，窓サイズ W，最小サポート σ であり，出力はすべての密集パタン P とその密集区間の集合 DI(P) の組の列挙である．

アルゴリズムは要素数 $k = 1$ から始め，サイズ k の密集パタン集合 L_k からサイズ $k+1$ の候補を生成し，各候補に対して密集区間を計算するという手順を繰り返す．探索空間の削減には，(1) アイテムセットの反単調性による候補パタンの枝刈りと，(2) 単一アイテムの密集区間の積集合による候補区間の絞り込みの 2 種類を用いる．Apriori-window のアルゴリズムを Algorithm 1 に示す．

4.2 反単調性

命題 1 (区間サポートの反単調性)．$P' \supseteq P$ ならば，任意の l, W に対して $sup(P',l,W) \le sup(P,l,W)$.

Proof. $P' \supseteq P$ より P' の出現は P の全アイテムを含む必要があるため $occ(P',D) \subseteq occ(P,D)$ が成り立つ．ゆえに窓内の出現数も $sup(P',l,W) \le sup(P,l,W)$. □

命題 1 により, 密集パタン抽出問題において Apri-

Algorithm 1 Apriori-window

入力: item_ts: item-to-occ map; W: window size; σ: min support

出力: F: map from pattern to dense intervals

$F, L_1, S \leftarrow \emptyset, \emptyset$, empty map
for x in sorted keys(item_ts) **do**
  $\mathrm{DI}(x) \leftarrow \mathrm{Scan}(\mathrm{occ}(x), W, \sigma, \mathrm{unr})$
  if $\mathrm{DI}(x) \neq \emptyset$ **then**
    $F[\{x\}] \leftarrow \mathrm{DI}(x)$; $L_1 \leftarrow L_1 \cup \{\{x\}\}$; $S[x] \leftarrow \mathrm{DI}(x)$
  end if
end for
$k \leftarrow 2$; $L_p \leftarrow L_1$
while $L_p \neq \emptyset$ **do**
  $C_k \leftarrow \mathrm{AprioriJoin}(L_p)$ on first $k{-}2$ items
  $C_k \leftarrow \{X \in C_k \mid \text{all } (k{-}1)\text{-subsets in } L_p\}$
  $L_k \leftarrow \emptyset$
  for $X \in C_k$ **do**
    $\mathrm{occ}(X) \leftarrow \bigcap_{x \in X} \mathrm{occ}(x)$
    if $\mathrm{occ}(X) = \emptyset$ **then**
      continue
    end if
    $R_X \leftarrow \mathrm{cand}(X)$ using $S[x]$ for $x \in X$
    if $R_X = \emptyset$ **then**
      continue
    end if
    $\mathrm{DI}(X) \leftarrow \mathrm{Scan}(\mathrm{occ}(X), W, \sigma, R_X)$
    if $\mathrm{DI}(X) \neq \emptyset$ **then**
      $F[X] \leftarrow \mathrm{DI}(X)$; $L_k \leftarrow L_k \cup \{X\}$
    end if
  end for
  $L_p \leftarrow L_k$; $k \leftarrow k + 1$
end while
return F

ori と同様の候補生成・枝刈り戦略が成立する．

命題 2 (密集区間の包含関係)**.** 任意の $x \in P$ に対し，P のすべての密集区間は x の密集区間のいずれかに包含される．

Proof. P の密集区間 $[s, e]$ に対し，ある $l \in [s, e - W]$ で $sup(P, l, W) \geq \sigma$．命題 1（反単調性）より，任意の $x \in P$ について $sup(x, l, W) \geq sup(P, l, W) \geq \sigma$ となるため，$[l, l + W]$ は x の密集窓である．ゆえに l は x の密集区間内に含まれる．$[s, e]$ の左端は l に依存して決まるため，$[s, e]$ は x の密集区間に包含される． □

命題 2 から，サイズ $k \geq 2$ のパタン P の密集区間は，P を構成する全アイテムの 単一アイテムの密集区間の積集合（$\bigcap_{x \in P} \mathrm{DI}(x)$）の外には存在しない．この性質を用いて，密集区間の探索範囲を候補区間集合

$$cand(P) = \left\{ (s, e) \in \bigcap_{x \in P} \mathrm{DI}(x) \;\middle|\; e - s \geq W \right\}$$

に限定できる．$cand(P)$ が空であれば P は密集パタンでないため探索を打ち切る．

4.3 スライディング窓による密集区間検出

密集区間を検出するアルゴリズムを Algorithm 2 に示す．スライディング窓による区間検出は，スキャン回数が計算効率に影響する．スキャン回数を削減する方策として，ストライドスキップを導入する．

ストライドスキップ：窓 $[l, l + W]$ 内の出現数が $\mathrm{cnt} \geq \sigma$ のとき，最後の σ 個の出現の先頭位置を t_{keep} とすれば，窓開始位置 l を $t_{\mathrm{keep}} + 1$ に前進させる．

命題 3 (ストライドスキップの安全性)**.** 窓 $[l, l+W]$ 内の出現数を cnt とし，$cnt \geq \sigma$ のとき，この窓から最後の σ 個の出現の先頭 t_{keep} とすれば，$l \leq l' \leq t_{keep}$ を満たす任意の l' に対しても $[l', l' + W]$ は密集窓である．ゆえに，l を $t_{keep} + 1$ まで前進させても密集区間を見落とさない．

Proof. 窓 $[l, l + W]$ に含まれる出現を昇順に $t_1 \leq t_2 \leq \cdots \leq t_{\mathrm{cnt}}$（$\mathrm{cnt} \geq \sigma$）とする．最後の σ 個の出現 $t_{\mathrm{cnt}-\sigma+1}, t_{\mathrm{cnt}-\sigma+2}, \ldots, t_{\mathrm{cnt}}$ を考える．$l \leq l' \leq t_{\mathrm{cnt}-\sigma+1}$ を満たす任意の l' に対し，$l' \leq t_{\mathrm{cnt}-\sigma+1}$ および $t_{\mathrm{cnt}} \leq l + W \leq l' + W$（$l' \geq l$ より）によ

り，これら σ 個の出現がすべて $[l', l'+W]$ に含まれる．よって $[l', l'+W]$ は密集窓である． □

命題 3 によりストライドスキップの安全性が保証される．窓内の出現回数 cnt が大きいほど $\mathrm{cnt}-\sigma$ が大きくなり，スキップ幅が大きくなるため，出現時点が密集しているパタンであるほどスキャン時の計算効率の向上が期待できる．**RQ1 への回答：パタン空間が満たす反単調性と密集区間の包含関係から，Apriori アルゴリズムを拡張することで厳密解法を実現することが可能である．またストライドスキップにより，区間探索の厳密性を保ちつつ効率化を図る．**

5 実験

5.1 実験 A：既存手法との比較

本実験では，既存手法は密集するパタンの同定と密集区間の検出を精度良く行えるかを検証する．SPMF [40] で公開されている 3 種類のベンチマークデータセット Retail, OnlineRetail, ChicagoCrime を使用する．各データセットの統計量を Table 3 に示す．

表 3 実験データセット

データセット	#Trans	#Items	平均長
Retail	88,162	14,089	10.3
OnlineRetail	540,455	2,147	4.4
ChicagoCrime	2,662,309	34	1.8

比較手法として，以下の手法と比較した．

- FIM：頻出アイテムセットマイニング [1]
- PFPM：周期的頻出パタンマイニング [23]
- PPFPM：部分的周期的頻出パタンマイニング [28]
- LPFIM：局所周期的頻出アイテムセットマイニング [34]
- LPPM：局所周期的パタンマイニング [35]
- RPM：周期区間繰り返しパタンマイニング [36]
- Span：各パタンの最初から最後の出現タイムスタンプを 1 区間として出力する参照手法．各データセットにおける正解密集期間の局所性を確認することを目的とする．

表 4 実験 A における正解密集パタン数（長さ 2 以上）．表頭の数値は W/σ を表す．

データセット	250/25	500/50	750/75	1000/100
Retail	171	110	89	81
Chicago	63	42	28	23

データセット	100/10	250/25	500/50
OnlineRetail	355	64	11

Apriori-window が抽出したパタン集合 $\mathcal{P}^*$，その密集区間 $\mathrm{DI}^*(P)$ を正解とした．パラメータ (W, σ) は Retail, ChicagoCrime で $\{(250,25),(500,50),(750,75),(1000,100)\}$，OnlineRetail で $\{(100,10),(250,25),(500,50)\}$ と設定する．評価対象はアイテムセットの長さが 2 以上のパターンに限定し，各設定での正解密集パタン数は Table 4 に示す通りである．

各手法の抽出精度は F1 スコア，mean Jaccard, mean Temporal Precision の 3 指標で評価する．ただし区間を出力しない手法(FIM, PFPM, PPFPM)は F1 スコアで評価する各パタン P に対し，$G(P) = \bigcup_{[s,e]\in \mathrm{DI}^*(P)}[s,e]$，$\hat{G}(P) = \bigcup_{[s,e]\in \widehat{\mathrm{DI}}(P)}[s,e]$ をそれぞれ正解・予測区間の時間的被覆（$|\cdot|$ は時間長），$\hat{\mathcal{P}}$ を各手法の予測パタン集合とする．

F1 スコアは正解パタンと予測パタンの一致に基づく調和平均である：

$$\mathrm{F1} = \frac{2\,|\hat{\mathcal{P}} \cap \mathcal{P}^*|}{|\hat{\mathcal{P}}| + |\mathcal{P}^*|}$$

mean Jaccard は各正解パタンの正解・予測区間の時間的重複で算出する Jaccard 係数の，全正解パタンにおける平均である：

$$\text{mean Jaccard} = \frac{1}{|\mathcal{P}^*|} \sum_{P\in\mathcal{P}^*} \frac{|G(P) \cap \hat{G}(P)|}{|G(P) \cup \hat{G}(P)|}$$

mean Temporal Precision は正しく同定されたパタン（$P \in \hat{\mathcal{P}} \cap \mathcal{P}^*$）に限り算出する，予測区間の

表 5　各比較手法の全パラメータ一覧．σ: 実験設定の最小サポート（$= W/10$）．N: PFPM 最大周期上限（Retail: 900，OnlineRetail: 3,500，Chicago: 10,000）．N': PPFPM 最大周期上限（Retail: 50, OnlineRetail: 500, Chicago: 900）．

手法	パラメータ	値・探索範囲	
FIM	$minSup$	σ	固定
PFPM	$maxPer$	$\{5, 10, \ldots, N\}$ (step 5)	探索
	$minSup$	σ	固定
PPFPM	$maxPer$	$\{5, 10, \ldots, N'\}$ (step 5)	探索
	$minPR$	$\{0.05, 0.10, \ldots, 0.95\}$	探索
	$minSup$	σ	固定
LPFIM	σ_ℓ	$\{10, 15, 20, 25, 30\}\%$	探索
	$minthd1$	$\{10, 15, \ldots, 100\}$ (step 5)	探索
	$minthd2$	$\{10, 20, \ldots, 1000\}$ (step 10)	探索
LPPM	$maxPer$	$\{5, 10, \ldots, 50\}$ (step 5)	探索
	$minDur$	$\{5, 10, \ldots, 1000\}$ (step 5)	探索
	$maxSoPer$	$\{5, 10, \ldots, 500\}$ (step 5)	探索
RPM	$maxPer$	$\{5, 10, \ldots, 250\}$ (step 5)	探索
	$minPS$	σ	固定
	$minRec$	1	固定

うち正解区間と重複する割合の平均である：

$$\text{mean TP} = \frac{1}{|\hat{\mathcal{P}} \cap \mathcal{P}^*|} \sum_{P \in \hat{\mathcal{P}} \cap \mathcal{P}^*} \frac{|G(P) \cap \hat{G}(P)|}{|\hat{G}(P)|}$$

既存手法はパラメータの設定次第で抽出精度が大きく変化する．そのため各手法のパラメータはグリッドサーチにより F1 スコアを最大化するように選択し，同率の場合は Jaccard 係数が高い設定を優先する．各手法のパラメータ探索空間を Table 5，各手法のベスト F1 パラメータは付録 B に示す．

LPPM は SPMF [40] で公開されている java コードを利用し，LPPM 以外の既存手法と Apriori-window は Rust で実装している．

Table 6 で，3 データセット・全窓サイズごとに全手法のベストパラメータにおける F1 スコア，mean Jaccard，mean Temporal Precision を示す．FIM の F1 スコアは 0.035 以下にとどまった．データ全体のサポートに従ってパタンを抽出するため，出現頻度は密集パタンと同程度であるものの分散して出現する非密集パタンを大量に抽出してしまい再現率は 1.0 である一方，適合率が極端に低い．PFPM・PPFPM はギャップ条件の導入により FIM と比べて F1 が改善され（PPFPM Retail: 0.782–0.926, Chicago: 0.740–0.818），出現間隔制約がパタン同定の精度に寄与する可能性を示唆している．

区間を出力する LPFIM・LPPM・RPM は Retail および Chicago で高い F1（0.866–0.989）を達成する設定が存在するが，Jaccard はデータセット・窓サイズによってばらつきが見られ，特に onlineretail において低い値となっている．これは，正解データである密集区間がスライディング窓の幅 W に基づく区間拡張を含んでおり，出現間隔を基にした既存手法では定義上正解区間の幅を再現できないことが原因と考えられる．そこで，mean Temporal Precision に基づき，パタンを同定できている設定においても区間の誤抽出が生じていることが確認しした．全手法において全データにおいて，パタンの出現区間全域を抽出する参照手法よりも高いことがわかる．このことから出現間隔による区間抽出は区間のフィルタリングとして一定の効果を持っていると考えられる．一方で Span のスコアが低いデータセットにおいて，F1 が高い設定でも TP が低下するケースが各手法で見られた．（例：RPM Chicago $W = 1000$：F1 $= 0.920$，TP $= 0.591$；LPPM OnlineRetail $W = 500$：F1 $= 0.957$，TP $= 0.358$）これは密集パタンをもれなく抽出するためにパラメータの制限を緩和することで区間の誤検出が発生している，つまりパタン同定と正確な区間抽出の間にトレードオフが見られることを示唆している．

RQ2 への回答：既存手法は密集パタンの同定には一定の有効性を示すが，高精度なパタン同定と密集区間検出の両立が困難である可能性がある．

5.2　実験 B：スケーラビリティ

本実験では，データの性質に対する Apriori-window の時間・メモリ使用量の増加傾向を確認する．合成データを用いてトランザクション

表 6　ベスト F1 パラメータにおける既存手法のパタン同定精度および区間検出精度．各手法のベストパラメータは付録 B を参照．Apriori-window は密集パタンに対応した厳密解法であるため F1 = Jaccard = TP = 1.000 となる．

			F1 スコア						Jaccard				Temporal Precision			
Dataset	W	σ	FIM	PFPM	PPFPM	LPFIM	LPPM	RPM	LPFIM	LPPM	RPM	Span	LPFIM	LPPM	RPM	Span
Retail	250	25	.009	.119	.782	.866	.917	.906	.205	.637	.652	.397	.896	.970	.936	.428
	500	50	.017	.120	.861	.830	.967	.941	.218	.715	.710	.526	.949	.988	.933	.609
	750	75	.025	.146	.908	.867	.989	.943	.206	.695	.713	.564	.957	.977	.942	.691
	1000	100	.035	.159	.926	.868	.981	.929	.201	.649	.652	.540	.962	.954	.945	.704
Chicago	250	25	.007	.615	.740	.897	.969	.928	.196	.502	.451	.035	.752	.761	.749	.035
	500	50	.007	.627	.743	.886	.952	.963	.337	.514	.424	.042	.817	.853	.716	.042
	750	75	.006	.604	.776	.945	.929	.963	.303	.150	.330	.058	.743	.754	.796	.058
	1000	100	.007	.622	.818	.957	.936	.920	.156	.182	.346	.069	.673	.730	.591	.069
OnlineRetail	100	10	.013	.312	.770	.732	.774	.938	.040	.065	.216	.012	.728	.762	.896	.012
	250	25	.003	.230	.623	.814	.832	.699	.027	.097	.311	.008	.432	.637	.741	.008
	500	50	.001	.500	.909	1.000	.957	.909	.135	.239	.163	.013	.687	.358	.244	.013

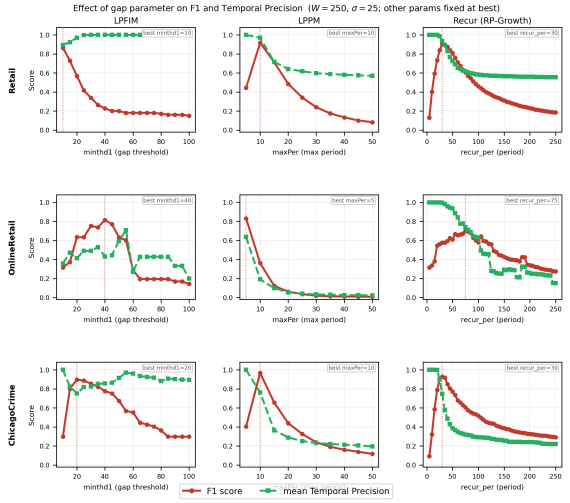


図 1　出現間隔に関する制約パラメータ（LPFIM: *minthd1*, LPPM: *maxPer*, RPM: recur_per）に対する F1 スコア（赤，実線）および mean Temporal Precision（緑, 破線）の変化（$W = 250$, $\sigma = 25$；他パラメータは最良 F1 設定に固定）．縦点線は最良 F1 を与えるギャップ値を示す．

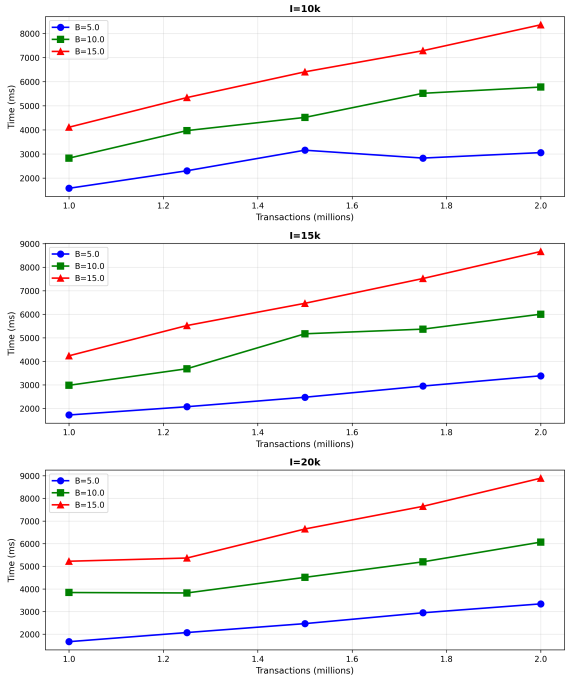


図 2　スケーラビリティ実験：平均実行時間（$T \in [1{\times}10^6, 2{\times}10^6]$, $I \in \{10\text{k}, 15\text{k}, 20\text{k}\}$, $B \in \{5, 10, 15\}$, 10 試行平均）．

数 $T \in \{1.0, 1.25, 1.5, 1.75, 2.0\} \times 10^6$，アイテム数 $I \in \{10000, 15000, 20000\}$，平均バスケット長 $B \in \{5, 10, 15\}$ のパラメータを変化させた 45 種類の設定で 10 回ずつ実行し，平均実行時間と最大瞬間メモリ使用量を計測する．疑似データの詳細な生成方法は付録 A に記載する．実行時間測定時の実行環境は 11th Gen Intel Core i7-1185G7 @ 3.00 GHz，RAM 32 GB である．

各データセットにおける実行時間を Fig. 2，最大瞬間メモリ使用量を Fig. 3 に示す．実行時間・メモリ使用量はいずれもトランザクション数・アイテム数・バスケット長に対して概ね線形に増加し，最大設定（$T = 2 \times 10^6$，$I = 20000$，$B = 15$）でも平均 8.9 秒，メモリ 333 MiB であった．すべての設

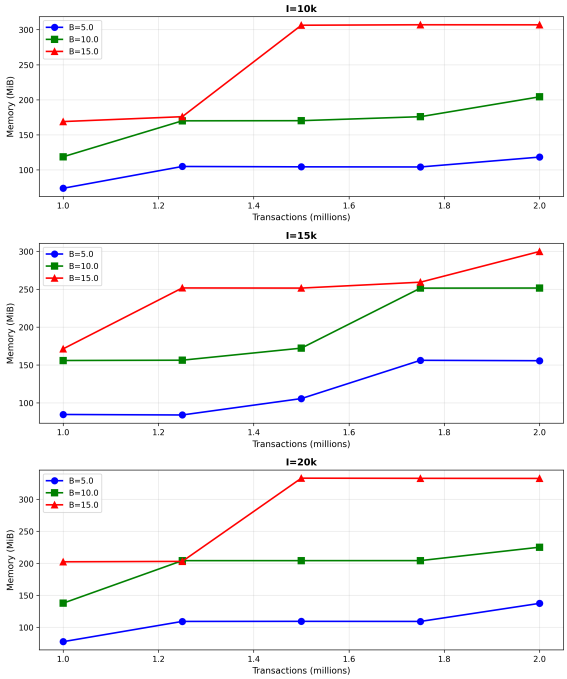


図 3　スケーラビリティ実験：最大瞬間メモリ使用量（同条件，10 試行平均）．線種が B，色が I の設定に対応する．

定において抽出されたパタン数は 1545〜1550 個の範囲であり，パラメータ変動による密集パタン数の変化は小さく，実行時間やメモリ変動の主因はデータサイズとバスケット長であることが確認された．また Fig. 2，Fig. 3 の両者で平均バスケット長の増加（5 → 15）による実行時間やメモリ使用量の増加が確認された．これは平均バスケット長の増加により，各アイテムの出現時点数と候補パタン数の増加したためだと考えられる．一方でアイテム数 I の増加（10k → 20k）の影響は平均バスケット長と比べて相対的に小さい．これはアイテムの増加によって長さ 1 の候補パタンが増加するものの，逆単調性を利用した枝刈りにより，長いパタンでは埋め込んだパタンに限定して探索できているためだと考えられる．**RQ3 への回答：実行時間はトランザクション数・アイテム数・バスケット長に対してほぼ線形に増大し，最大設定（T=2×10^6，I=20k，B=15）でも 8.9 秒，333 MiB で処理可能であった．**

5.3　実験 C：アブレーション分析

提案手法の 2 つの探索空間を削減する処理の効果を検証する．アブレーション実験で用いた各モデルを以下のように定義する：

- **Baseline**：最適化を適用しない基本実装．候補探索は全窓位置で実施される．
- **Intersect**：長さ 1 の密集パタンの密集区間の積集合による候補削減を適用する．しかし窓のスライディングは全位置で実施される．
- **Apriori-window**：積集合による削減に加えて，stride-skip 最適化を適用する．余剰出現数に基づいて窓のスキップを行い，不要なスキャン位置を削減する．

Table 7 にアブレーション実験の結果を示す．まず，Intersect モデルは Baseline に比べて Retail ではほぼ同等，Chicago では 40〜50% の実行時間削減，OnlineRetail では 10〜60% の削減を示す．積集合計算により候補区間を大幅に絞り込める場合，候補探索空間の削減がオーバーヘッドを上回る効果をもたらす．次に，Apriori-window モデルでは，Retail では全体として 94〜96% の削減，Chicago では 65〜77% の削減，OnlineRetail では 88〜94% の削減が達成され，stride-skip 最適化の顕著な効果が示される．窓サイズが大きくなるにつれて stride-skip の相対的な効果が向上する傾向が見られ，大きな窓ほど surplus が増加してスキップ幅が拡大するためと考えられる．

6　おわりに

本稿では，トランザクションデータからパタンとその密集区間を厳密に抽出する手法 Apriori-window を提案した．提案手法はスライディング窓による局所頻度の直接評価に基づき，出現間隔ベース手法に内在するパタン同定精度と区間検出精度のトレードオフを回避する．区間サポートの反単調性を利用した候補区間枝刈りと，余剰出現に基づくストライド調整により，実用的な効率で網羅的かつ厳密な密集パタン抽出を実現した．3 つの実データセットを用いた実験では，既存手法がパタン同定

表 7　アブレーション分析：各最適化成分の組み合わせによる実行時間の比較（単位 ms，10 回平均）

Dataset	W	σ	Baseline	Intersect	Apriori-window
Retail	250	25	3,313	3,111	164
	500	50	3,181	3,241	324
	750	75	3,744	3,145	184
	1000	100	3,190	3,106	140
Chicago	250	25	6,587	3,575	2,036
	500	50	5,202	3,023	1,303
	750	75	4,626	2,953	1,116
	1000	100	4,269	2,806	1,077
OnlineRetail	100	10	14,620	6,020	813
	250	25	7,320	5,631	488
	500	50	6,475	5,642	357

と密集区間検出の両立が困難であることを示し，合成データによるスケーラビリティ実験では百万トランザクション規模でも実行時間最大 8.9 秒・メモリ 333 MiB で動作することを確認した．

今後の課題として，実社会の幅広いデータへの適用，密集区間間の帰属関係の分析，およびストリームデータへのオンライン適用が挙げられる．

参考文献

[1] R. Agrawal and R. Srikant, “Fast algorithms for mining association rules,” in *Proc. VLDB*, 1994, pp. 487–499.

[2] M. J. Zaki, S. Parthasarathy, M. Ogihara, and W. Li, “New algorithms for fast discovery of association rules,” in *Proc. KDD*, 1997, pp. 283–296.

[3] J. Han, J. Pei, and Y. Yin, “Mining frequent patterns without candidate generation,” *ACM SIGMOD Record*, vol. 29, no. 2, pp. 1–12, 2000.

[4] P. Fournier-Viger, J. C. -W. Lin, B. Vo, T. T. Chi, J. Zhang, and H. B. Le, “A survey of itemset mining,” *WIREs Data Mining Knowl. Discov.* , vol. 7, no. 4, e1207, 2017.

[5] P. Fournier-Viger, W. Gan, Y. Wu, M. Nouioua, W. Song, T. Truong, and H. Duong, “Pattern mining: Current challenges and opportunities,” in *Proc. DASFAA Workshops*, LNCS 13248, 2022, pp. 34–49.

[6] J. M. Luna, P. Fournier-Viger, and S. Ventura, “Frequent itemset mining: A 25 years review,” *WIREs Data Mining Knowl. Discov.* , vol. 9, no. 6, e1329, 2019.

[7] B. Liu, W. Hsu, and Y. Ma, “Mining association rules with multiple minimum supports,” in *Proc. KDD*, 1999, pp. 337–341.

[8] C. F. Ahmed, S. K. Tanbeer, B. -S. Jeong, and Y. -K. Lee, “Efficient tree structures for high utility pattern mining in incremental databases,” *IEEE Trans. Knowl. Data Eng.* , vol. 21, no. 12, pp. 1708–1721, 2009.

[9] P. Fournier-Viger, J. C. -W. Lin, T. Truong-Chi, and R. Nkambou, “A survey of high utility itemset mining,” in *High-Utility Pattern Mining*, Springer, 2019, pp. 1–45.

[10] T. Berteloot, R. Khoury, and A. Durand, “Association rules mining with auto-encoders,” in *Proc. IDEAL*, LNCS, Springer, 2025.

[11] E. Karabulut, R. Pellicer-Valero, V. Degeler, and P. Fournier-Viger, “Learning semantic association rules from internet of things data,” arXiv:2412. 03417, 2024.

[12] J. Fischer and J. Vreeken, “Differentiable pattern set mining,” in *Proc. KDD*, 2021, pp. 383–392.

[13] S. Ghosh, A. Chakraborty, and S. Dey, “Probabilistic and reinforced mining of association rules,” arXiv:2506. 18155, 2025.

[14] A. Jamshed, B. Mallick, and P. Kumar, “Deep learning-based sequential pattern mining for progressive database,” *Soft Computing*, vol. 24, no. 22, pp. 17233–17246, 2020.

[15] M. K. Porwal and N. Porwal, “A novel deep learning model for high-utility item set

mining in transactional data," in *Intelligent Systems (ICMIB 2025)*, LNNS vol. 1623, Springer, 2026, pp. 267–280.

[16] Y. Djenouri, D. Djenouri, A. Belhadi, P. Fournier-Viger, and J. C. -W. Lin, "A new framework for metaheuristic-based frequent itemset mining," *Applied Intelligence*, vol. 48, pp. 4775–4791, 2018.

[17] A. Telikani, A. H. Gandomi, and A. Shahbahrami, "A survey of evolutionary computation for association rule mining," *Information Sciences*, vol. 524, pp. 318–352, 2020.

[18] Q. Wan and A. An, "Discovering transitional patterns and their significant milestones in transaction databases," *IEEE Trans. Knowl. Data Eng.* , vol. 21, no. 12, pp. 1692–1707, 2009.

[19] C. -Y. Chang, M. -S. Chen, and C. -H. Lee, "Mining general temporal association rules for items with different exhibition periods," in *Proc. ICDM*, 2002, pp. 59–66.

[20] C. -H. Lee, M. -S. Chen, and C. -R. Lin, "Progressive partition miner: An efficient algorithm for mining general temporal association rules," *IEEE Trans. Knowl. Data Eng.*, vol. 15, no. 4, pp. 1004–1017, 2003.

[21] J. Kleinberg, "Bursty and hierarchical structure in streams," *Data Mining and Knowledge Discovery*, vol. 7, no. 4, pp. 373–397, 2003.

[22] Z. Yang, Y. Gong, Q. He, Y. Zhang, and T. Yang, "BurstSketch: Finding bursts in data streams," in *Proc. ACM SIGMOD*, 2021, pp. 2375–2383.

[23] S. K. Tanbeer, C. F. Ahmed, B. -S. Jeong, and Y. -K. Lee, "Discovering periodic-frequent patterns in transactional databases," in *Proc. PAKDD*, 2009, pp. 242–253.

[24] R. U. Kiran, M. Kitsuregawa, and P. K. Reddy, "Efficient discovery of periodic-frequent patterns in very large databases," *J. Systems and Software*, vol. 112, pp. 110–121, 2016.

[25] P. Fournier-Viger *et al.* , "Discovering periodic high utility itemsets in a discrete sequence," in *High-Utility Pattern Mining*, Studies in Big Data vol. 51, Springer, 2021, pp. 157–181.

[26] K. Amphawan, P. Lenca, and A. Surarerks, "Mining top-K periodic-frequent pattern from transactional databases without support threshold," in *Proc. IAIT*, 2009, pp. 18–29.

[27] J. -Y. Chen, Y. -C. Chen, and S. -Y. Lee, "An efficient bit-based approach for mining skyline periodic itemset patterns," *Electronics*, vol. 12, no. 23, 4874, 2023.

[28] R. U. Kiran, J. Venkatesh, M. Toyoda, M. Kitsuregawa, and P. K. Reddy, "Discovering partial periodic-frequent patterns in a transactional database," *J. Systems and Software*, vol. 125, pp. 170–182, 2017.

[29] V. Radhakrishna, P. Kumar, and V. Janaki, "A survey on temporal databases and data mining," in *Proc. ICEMIS*, 2015, pp. 1–6.

[30] G. Dong and J. Li, "Efficient mining of emerging patterns: Discovering trends and differences," in *Proc. KDD*, 1999, pp. 43–52.

[31] K. -C. Yin, Y. -L. Hsieh, D. -L. Yang, and M. -C. Hung, "Association rule mining considering local frequent patterns with temporal intervals," *Applied Mathematics & Information Sciences*, vol. 8, no. 4, pp. 1879–1890, 2014.

[32] B. Saleh and F. Masseglia, "Time aware mining of itemsets," in *Proc. TIME*, 2008, pp. 93–97.

[33] B. Saleh and F. Masseglia, "Discovering fre-

quent behaviors: Time is an essential element of the context," *Knowledge and Information Systems*, vol. 28, no. 2, pp. 311–331, 2011.

[34] A. K. Mahanta, F. A. Mazarbhuiya, and H. K. Baruah, "Finding locally and periodically frequent sets and periodic association rules," in *Proc. PReMI*, 2005, pp. 576–582.

[35] P. Fournier-Viger, P. Yang, R. U. Kiran, S. Ventura, and J. M. Luna, "Mining local periodic patterns in a discrete sequence," *Information Sciences*, vol. 544, pp. 519–548, 2021.

[36] R. U. Kiran, H. Shang, M. Toyoda, and M. Kitsuregawa, "Discovering recurring patterns in time series," in *Proc. EDBT*, 2015, pp. 97–108.

[37] C. -H. Lee, C. -R. Lin, and M. -S. Chen, "Sliding-window filtering: An efficient algorithm for incremental mining," in *Proc. CIKM*, 2001, pp. 263–270.

[38] C. K. -S. Leung and Q. I. Khan, "DSTree: A tree structure for the mining of frequent sets from data streams," in *Proc. ICDM*, 2006, pp. 928–932.

[39] S. Aminikhanghahi and D. J. Cook, "A survey of methods for time series change point detection," *Knowledge and Information Systems*, vol. 51, no. 2, pp. 339–367, 2017.

[40] P. Fournier-Viger, J. C. -W. Lin, A. Gomariz, T. Gueniche, A. Soltani, Z. Deng, and H. T. Lam, "The SPMF open-source data mining library version 2," in *Proc. ECML-PKDD*, 2016, pp. 36–40.

[41] C. -H. Chee, J. Jaafar, I. A. Aziz, M. H. Hasan, and W. Yeoh, "Algorithms for frequent itemset mining: A literature review," *Artificial Intelligence Review*, vol. 52, pp. 2603–2621, 2019.

付録 A　スケーラビリティ実験における疑似データ生成方法

本研究では，提案手法のスケール評価を目的として疑似データを生成した．

背景トランザクションの生成では，トランザクション数 T，アイテム集合サイズ I，平均トランザクション長 B を入力とし，各トランザクション長を平均 B，標準偏差 $\max(1, B/3)$ の正規分布から生成して整数に丸め，0 以上 I 以下に切り詰めた後，対応する個数のアイテムを一様ランダムに重複なく抽出して構成した．また，埋め込んだパタン以外に長さ 2 以上のパタンが抽出されることを抑制するため，背景データにおけるアイテム出現頻度の期待値を調整し，背景部分に埋め込んだパタン以外の共起が生じにくいように設定した．

タイムスタンプは各トランザクションに 1 つずつ与え，埋め込み区間外では時刻差を $[5, 10]$ 範囲の離散一様分布に従って設定し，埋め込み区間内では所定の区間長を満たすように調整した．

その上で，以下のパラメータで密集パタンを埋め込んだ：

- 埋め込みパタンの長さ：5
- パタン種類数：50
- 各密集区間の長さ：10,000
- 密集区間の個数：1
- 各パタンの区間内出現回数：100

最終的に抽出対象となる長さ 2 以上のパタン総数を 1,300 種類に統制した．

本研究のスケーラビリティ実験（実験 B）で抽出されたパタン数を Table 8 に示す．すべての設定において抽出されたパタン数は 1,545〜1,550 個の範囲であり，バスケット長やアイテム数といったデータサイズパラメータの変動に対して，密集パタン数はほぼ一定値に保たれていることが確認された．

表 8　スケーラビリティ実験：抽出パタン数

T	I	$B=5$	$B=10$	$B=15$	平均
1M	10k	1545	1545	1547	1545.7
	15k	1549	1547	1548	1548.0
	20k	1550	1550	1548	1549.3
1.25M	10k	1546	1547	1545	1546.0
	15k	1548	1548	1547	1547.7
	20k	1548	1544	1549	1547.0
1.5M	10k	1548	1549	1547	1548.0
	15k	1548	1549	1549	1548.7
	20k	1547	1548	1548	1547.7
1.75M	10k	1546	1547	1547	1546.7
	15k	1547	1546	1548	1547.0
	20k	1548	1550	1548	1548.7
2M	10k	1550	1549	1547	1548.7
	15k	1550	1548	1550	1549.3
	20k	1550	1549	1548	1549.0

付録 B　各手法のベスト F1 パラメータ一覧

Table 6 の各手法・各設定における F1 最大化パラメータを以下に示す.

■FIM　全てのデータセットにおいて $minSup$ に実験設定の最小支持度 σ_{exp} を設定する.

■LPFIM

- Retail:
  - $W=250, \sigma=25$: $\sigma_\ell=15\%$, $minthd1=10$, $minthd2=20$
  - $W=500, \sigma=50$: $\sigma_\ell=15\%$, $minthd1=10$, $minthd2=30$
  - $W=750, \sigma=75$: $\sigma_\ell=20\%$, $minthd1=10$, $minthd2=20$
  - $W=1000, \sigma=100$: $\sigma_\ell=20\%$, $minthd1=10$, $minthd2=30$
- Chicago:
  - $W=250, \sigma=25$: $\sigma_\ell=10\%$, $minthd1=20$, $minthd2=90$
  - $W=500, \sigma=50$: $\sigma_\ell=10\%$, $minthd1=35$, $minthd2=200$
  - $W=750, \sigma=75$: $\sigma_\ell=10\%$, $minthd1=45$, $minthd2=290$
  - $W=1000, \sigma=100$: $\sigma_\ell=10\%$, $minthd1=25$, $minthd2=300$
- OnlineRetail:
  - $W=100, \sigma=10$: $\sigma_\ell=15\%$, $minthd1=10$, $minthd2=10$
  - $W=250, \sigma=25$: $\sigma_\ell=15\%$, $minthd1=40$, $minthd2=10$
  - $W=500, \sigma=50$: $\sigma_\ell=10\%$, $minthd1=55$, $minthd2=100$

■LPPM

- Retail:
  - $W=250, \sigma=25$: $maxPer=10$, $minDur=165$, $maxSoPer=75$
  - $W=500, \sigma=50$: $maxPer=10$, $minDur=425$, $maxSoPer=105$
  - $W=750, \sigma=75$: $maxPer=10$, $minDur=635$, $maxSoPer=160$
  - $W=1000, \sigma=100$: $maxPer=10$, $minDur=685$, $maxSoPer=145$
- Chicago:
  - $W=250, \sigma=25$: $maxPer=10$, $minDur=145$, $maxSoPer=125$
  - $W=500, \sigma=50$: $maxPer=10$, $minDur=350$, $maxSoPer=185$
  - $W=750, \sigma=75$: $maxPer=15$, $minDur=335$, $maxSoPer=10$
  - $W=1000, \sigma=100$: $maxPer=15$, $minDur=460$, $maxSoPer=15$
- OnlineRetail:
  - $W=100, \sigma=10$: $maxPer=5$, $minDur=25$, $maxSoPer=90$
  - $W=250, \sigma=25$: $maxPer=5$, $minDur=50$, $maxSoPer=55$
  - $W=500, \sigma=50$: $maxPer=10$,

$minDur = 205$, $maxSoPer = 120$

■PFPM

- Retail:
  - $W = 250, \sigma = 25$: $maxPer = 885$, $minSup = 25$
  - $W = 500, \sigma = 50$: $maxPer = 255$, $minSup = 50$
  - $W = 750, \sigma = 75$: $maxPer = 255$, $minSup = 75$
  - $W = 1000, \sigma = 100$: $maxPer = 255$, $minSup = 100$
- Chicago:
  - $W = 250, \sigma = 25$: $maxPer = 6050$, $minSup = 25$
  - $W = 500, \sigma = 50$: $maxPer = 3655$, $minSup = 50$
  - $W = 750, \sigma = 75$: $maxPer = 3655$, $minSup = 75$
  - $W = 1000, \sigma = 100$: $maxPer = 3560$, $minSup = 100$
- OnlineRetail:
  - $W = 100, \sigma = 10$: $maxPer = 3400$, $minSup = 10$
  - $W = 250, \sigma = 25$: $maxPer = 1165$, $minSup = 25$
  - $W = 500, \sigma = 50$: $maxPer = 785$, $minSup = 50$

■PPFPM

- Retail:
  - $W = 250, \sigma = 25$: $maxPer = 50$, $minPR = 0.90$, $minSup = 25$
  - $W = 500, \sigma = 50$: $maxPer = 50$, $minPR = 0.95$, $minSup = 50$
  - $W = 750, \sigma = 75$: $maxPer = 50$, $minPR = 0.95$, $minSup = 75$
  - $W = 1000, \sigma = 100$: $maxPer = 50$, $minPR = 0.95$, $minSup = 100$
- Chicago:
  - $W = 250, \sigma = 25$: $maxPer = 15$, $minPR = 0.30$, $minSup = 25$
  - $W = 500, \sigma = 50$: $maxPer = 185$, $minPR = 0.95$, $minSup = 50$
  - $W = 750, \sigma = 75$: $maxPer = 45$, $minPR = 0.75$, $minSup = 75$
  - $W = 1000, \sigma = 100$: $maxPer = 45$, $minPR = 0.75$, $minSup = 100$
- OnlineRetail:
  - $W = 100, \sigma = 10$: $maxPer = 105$, $minPR = 0.55$, $minSup = 10$
  - $W = 250, \sigma = 25$: $maxPer = 70$, $minPR = 0.65$, $minSup = 25$
  - $W = 500, \sigma = 50$: $maxPer = 80$, $minPR = 0.80$, $minSup = 50$

■RPM

- Retail:
  - $W = 250, \sigma = 25$: $maxPer = 30$, $minPS = 25$, $minRec = 1$
  - $W = 500, \sigma = 50$: $maxPer = 40$, $minPS = 50$, $minRec = 1$
  - $W = 750, \sigma = 75$: $maxPer = 45$, $minPS = 75$, $minRec = 1$
  - $W = 1000, \sigma = 100$: $maxPer = 45$, $minPS = 100$, $minRec = 1$
- Chicago:
  - $W = 250, \sigma = 25$: $maxPer = 30$, $minPS = 25$, $minRec = 1$
  - $W = 500, \sigma = 50$: $maxPer = 35$, $minPS = 50$, $minRec = 1$
  - $W = 750, \sigma = 75$: $maxPer = 35$, $minPS = 75$, $minRec = 1$
  - $W = 1000, \sigma = 100$: $maxPer = 45$, $minPS = 100$, $minRec = 1$
- OnlineRetail:
  - $W = 100, \sigma = 10$: $maxPer = 40$, $minPS = 10$, $minRec = 1$
  - $W = 250, \sigma = 25$: $maxPer = 75$, $minPS = 25$, $minRec = 1$

– $W = 500, \sigma = 50$: $maxPer = 80$, $minPS = 50$, $minRec = 1$

Algorithm 2 Scan

入力: occ: sorted occurrence positions; W: window size; σ: min support; R: scan ranges

出力: DI: dense interval list

DI, recorded $\leftarrow \emptyset$
for $(c_s, c_e) \in R$ **do**
  $j \leftarrow$ LB(occ, c_s); $l \leftarrow \max(c_s, \max(0, \text{occ}[j + \sigma - 1] - W))$
  in_dense, s, $d \leftarrow$ false, $\perp$, $\perp$
  while $l \leq c_e$ **do**
    if $l \in$ recorded block $[a, b]$ **then**
      $l \leftarrow b + 1$; continue
    end if
    cnt $\leftarrow$ occurrence in window $[l, l + W]$
    if cnt $< \sigma$ **then**
      if in_dense and $d + W - s \geq W$ **then**
        Register$(s, d + W,$ recorded$)$
      end if
      in_dense, s, $d \leftarrow$ false, $\perp$, $\perp$
      $l \leftarrow \max(l{+}1, \text{occ}[\text{UB}(occ, l{+}W)]{-}W)$
    else
      keep $\leftarrow$ occ[LB(occ, l) + cnt $- \sigma$]
      if not in_dense **then**
        $s \leftarrow l$; $d \leftarrow$ keep; in_dense $\leftarrow$ true
      else
        $d \leftarrow \max(d,$ keep$)$
      end if
      if keep $+1 > c_e$ **then**
        $d \leftarrow \min(d, c_e)$; break
      else
        $l \leftarrow$ keep $+1$
      end if
    end if
  end while
  if in_dense and $d + W - s \geq W$ **then**
    Register$(s, d + W,$ recorded$)$
  end if
end for
return DI